
FeaStNet: Feature-Steered Graph Convolutions for 3D Shape Analysis

School of Industrial and Management Engineering, Korea University

Jungin Kim

Contents

- ❖ Research Purpose
- ❖ Proposed Method
- ❖ Experiment
- ❖ Conclusion

Research Purpose

- ❖ FeaStNet: Feature-Steered Graph Convolutions for 3D Shape Analysis (CVPR 2018)
 - ✓ 그리노블 대학에서 연구하였고, 2022년 2월 20일 기준으로 230회 인용됨
 - ✓ 그래프 구조 데이터, 3D shape mesh와 같은 형태의 데이터에 **효과적인 GCN 모델** 제시함

FeaStNet: Feature-Steered Graph Convolutions for 3D Shape Analysis

Nitika Verma

Edmond Boyer

Jakob Verbeek

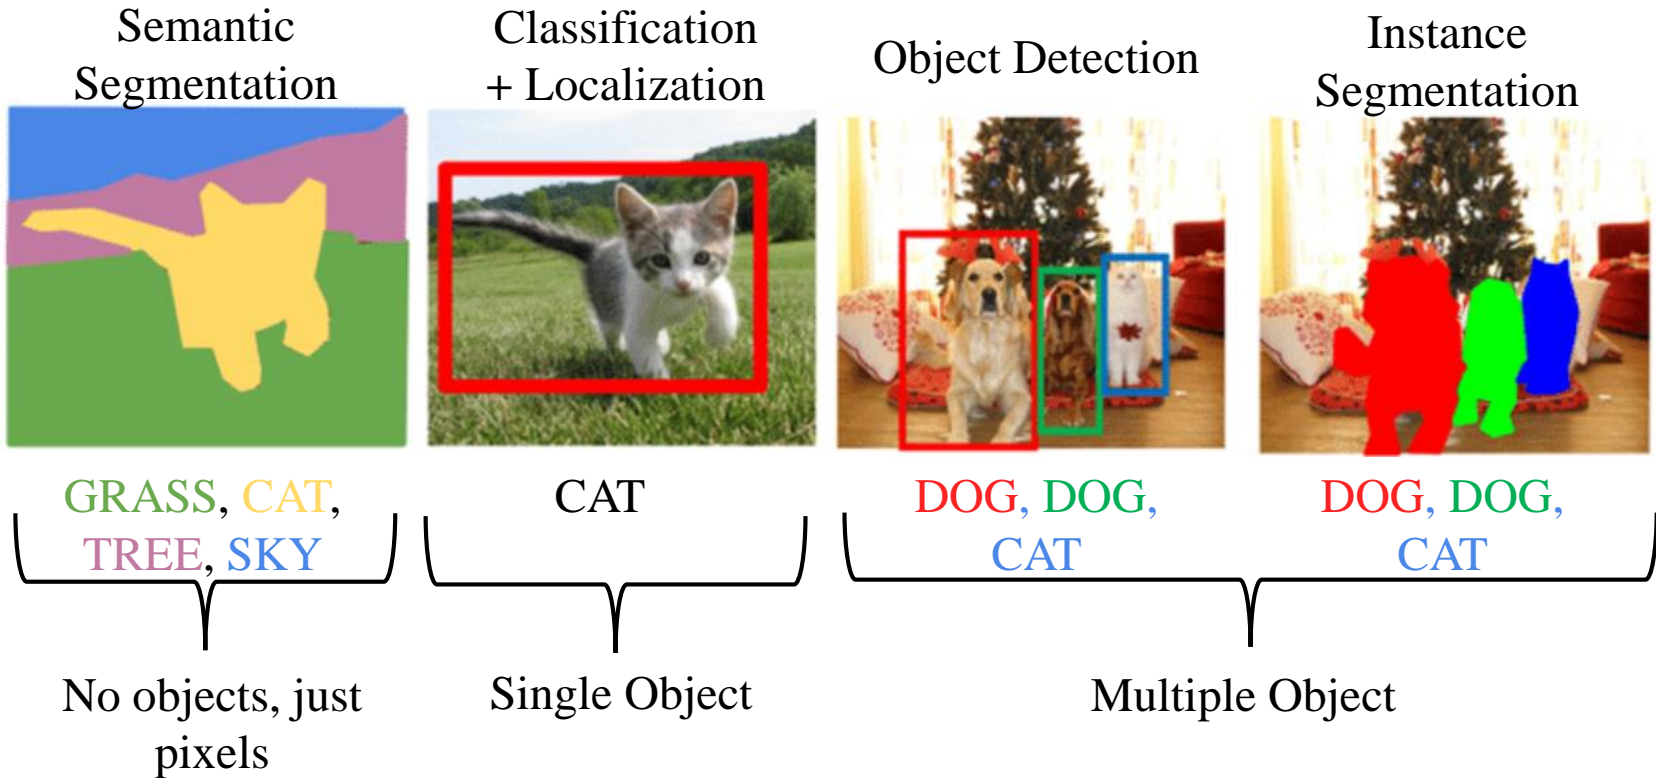
Univ. Grenoble Alpes, Inria, CNRS, Grenoble INP, LJK, 38000 Grenoble, France

Abstract

Convolutional neural networks (CNNs) have massively impacted visual recognition in 2D images, and are now ubiquitous in state-of-the-art approaches. CNNs do not easily extend, however, to data that are not represented by regular grids, such as 3D shape meshes or other graph-structured data, to which traditional local convolution operators do not directly apply. To address this problem, we propose a novel graph-convolution operator to establish correspondences between filter weights and graph neighborhoods with arbitrary connectivity. The key novelty of our approach is that these correspondences are dynamically computed from features learned by the network, rather than relying on predefined static coordinates over the graph as in previous work. We obtain excellent experimental results that significantly improve over previous state-of-the-art shape correspondence results. This shows that our approach can learn effective shape representations from raw input coordinates, without relying on shape descriptors.


Research Purpose

- ❖ 컴퓨터 비전, 자연어 처리를 포함한 여러 연구 분야에 효과적인 방법론이 많이 개발됨
- ❖ 특히, 이미지 분류, 객체 탐지 등의 문제 해결에 특화된 CNN 계열이 많이 개발됨



Research Purpose


- ❖ 3차원 구조의 데이터에 **CNN 적용이 한계**가 있음
- ❖ 소셜 네트워크, 분자 구조를 포함하는 그래프 구조의 데이터와 같은 3차원 구조 데이터에 일반화된 방법론이 제시됨
 - 하지만, 3차원 구조 데이터 정보를 제대로 활용할 수 없다는 한계가 존재
- ❖ 이를 위해 본 논문에서는 3차원 구조 데이터 정보를 잘 활용하고 **graph convolution 연산에 기반**한 FeaStNet을 제안함




<FeaStNet에 의해 예측된 Shape Correspondence를 활용한 Texture Transfer>

Proposed Method

- ❖ 기존의 CNN에서는 **1대1 매핑**을 통해 convolution 연산을 진행함
 - ❖ 하지만, graph convolution 연산에서는 **모든 가중치와 연산**을 진행함
 - ✓ $q_m(x_i, x_j)$: m개의 가중치 행렬에 대한 x_i 의 이웃인 x_j 간에 가중치
- 본 논문에서는 Convolutional filter weights를 재구성하여 FeaStNet 구조에 적용함



<기존 CNN에서의 convolution 연산>

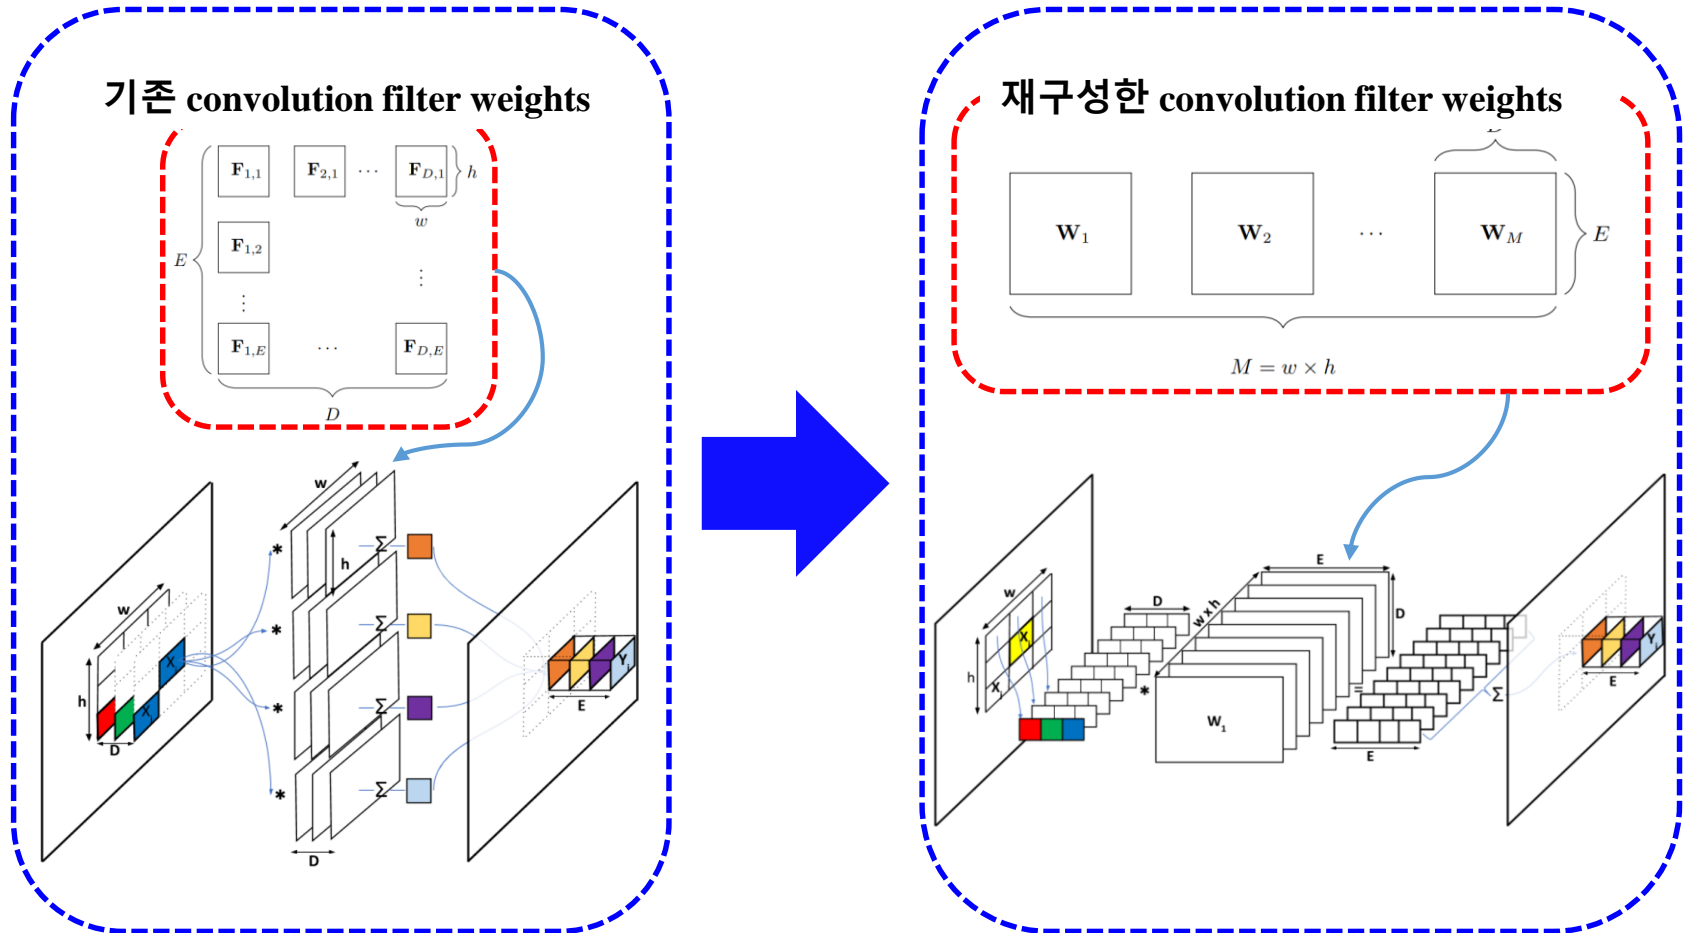


<GCN에서의 convolution 연산>

Proposed Method

$$y_i = b + \sum_{m=1}^M W_m X_j(m, i)$$

- ❖ 기존 CNN 구조의 convolution filter weights를 재구성함



Proposed Method


❖ 재구성한 convolution filter weights를 적용한 FeaStNet

✓ N_i : i 의 이웃 노드의 집합 (i 포함)

✓ $q_m(x_i, x_j)$: m 개의 가중치 행렬에 대한 x_i 의 이웃인 x_j 간에 가중치

$$\mathbf{y}_i = \mathbf{b} + \sum_{m=1}^M \frac{1}{|\mathcal{N}_i|} \sum_{j \in \mathcal{N}_i} q_m(\mathbf{x}_i, \mathbf{x}_j) \mathbf{W}_m \mathbf{x}_j$$

❖ 가중치 행렬과 노드 i 의 이웃 노드 j 에 1대1 대응이 아닌 모든 M 개의 가중치 행렬과 j 번째 이웃 노드와의 연산을 진행



Proposed Method

- ❖ 본 논문에서는 $q_m(x_i, x_j)$ 을 사용하여 m 번째 가중치 행렬과 노드 i 의 이웃 노드인 j 를 매핑하는 함수를 정의함 → **Feature-Steered assignment function**
- ❖ Feature-Steered assignment function의 가중치는 중심 노드 i 와 이웃 노드인 j 에 해당하는 가중치 행렬의 지역적인 feature 벡터와의 선형 결합 형태에 soft-max를 사용하여 정의함
 - ✓ $q_m(x_i, x_j) \propto \exp(u_m^T x_i + v_m^T x_j + c_m)$, with $\sum_{m=1}^M q_m(x_i, x_j) = 1$
- ❖ 위의 식으로 인해 노드 i 의 업데이트에 관련된 가중치는 중심 노드의 이웃 노드 수에 관계없이 항상 가중합이 1이 됨
 - ✓ $\sum_{j \in N_i} \frac{1}{|N_i|} \sum_{m=1}^M q_m(x_i, x_j) = \sum_{j \in N_i} \frac{1}{|N_i|} = 1$

Experiment


- ❖ 본 연구에서 실험을 위해 FAUST human shape dataset을 사용함
 - ✓ 6890개의 꼭지점을 각각 갖고 있는 100개의 mesh들로 구성
 - ✓ 각각 10가지 다른 자세의 10가지 모양으로 구성
 - ✓ Training data : 80개의 meshes, Test data : 20개의 meshes



<다양한 연령대와 체형을 보여주는FAUST human shape dataset>

Experiment

- ❖ FeaStNet을 사용해 3D mesh들 간에 3차원 shape correspondence 평가 실험을 진행함
- ❖ FeaStNet의 입력으로 두 가지 Vertex descriptor를 사용함
 - ✓ SHOT : Signature of Histograms of Orientations
 - ✓ XYZ : raw vertex coordinates



<Shape correspondence>

Experiment

❖ 평가 지표

- ✓ **정확도 : correspondence 예측이 정확하게 된 vertex의 수**
 - ✓ Geodesic distance 관점에서 correspondence 예측에 대한 에러를 보여줌
- 입력으로 XYZ vertex descriptor를 사용했을 때 좋은 성능을 보임

Translation inv.	yes	no
XYZ	86%	28%
SHOT	63%	58%

<Shape correspondence 정확도>

Experiment

❖ 평가 지표


- ✓ **정확도 : correspondence 예측이 정확하게 된 vertex의 수**
- ✓ Geodesic distance 관점에서 correspondence 예측에 대한 에러를 보여줌
- 입력으로 XYZ vertex descriptor를 사용했을 때 좋은 성능을 보임
- 최근 state-of-the-art 방법론과 비교했을 때 가장 좋은 성능을 보임

Method	Input	Accuracy
Logistic Regr.	SHOT	39.9%
PointNet [19]	SHOT	49.7%
GCNN [14], w/o refinement	SHOT	42.3%
GCNN [14], w/ refinement	SHOT	65.4%
ACNN [2], w/o refinement	SHOT	60.6%
ACNN [2], w/ refinement [17]	SHOT	62.4%
MoNet [15], w/o refinement	SHOT	73.8%
MoNet [15], w/ refinement [29]	SHOT	88.2%
FeaStNet, w/o refinement	XYZ	88.1%
FeaStNet, w/ refinement [29]	XYZ	92.2%
FeaStNet, multi scale, w/o refinement	XYZ	98.6%
FeaStNet, multi scale, w/ refinement [29]	XYZ	98.7%
FeaStNet, multi scale, w/o refinement	SHOT	90.9%

Experiment

❖ 평가 지표

- ✓ 정확도 : correspondence 예측이 정확하게 된 vertex의 수
 - ✓ **Geodesic distance 관점에서 correspondence 예측에 대한 에러를 보여줌**
- 입력으로 XYZ vertex descriptor를 사용했을 때 좋은 성능을 보임



<Geodesic distance 관점에서 바라본 Shape correspondence 정확도>

Conclusion

❖ Conclusion

- 그래프 구조 데이터, 3D shape mesh와 같은 형태의 데이터에 **CNN 적용에 한계가 있음**
- **3차원 구조 정보를 효과적으로 활용**하는데 한계가 존재함
- 위와 같은 두 가지 제약 조건을 해결하기 위해 **convolution 연산을 기반으로 하는 새로운 방법론**을 제시함
 - ✓ FeaStNet: local filtering에 기반하고 일반적인 그래프 구조에 적용할 수 있는 graph-convolutional 구조
- 본 논문에서 제시한 방법론이 state-of-the-art 방법론보다 더 좋은 성능을 보이는 것을 확인
 - ✓ 특히 **shape correspondence 예측 task**에서 다른 방법론에 비해 더 좋은 성능을 이룸

Thank You

Conclusion

❖ References

- F. Bogo, J. Romero, M. Loper, and M. Black. FAUST: Dataset and evaluation for 3D mesh registration. In CVPR, 2014.
- D. Boscaini, J. Masci, E. Rodola, and M. Bronstein. Learning shape correspondence with anisotropic convolutional neural networks. In NIPS, 2016.
- F. Monti, D. Boscaini, J. Masci, E. Rodola, J. Svoboda, and M. Bronstein. Geometric deep learning on graphs and manifolds using mixture model CNNs. In CVPR, 2017.
- Salvi, Samuele, Federico Tombari, and Luigi Di Stefano. "SHOT: Unique signatures of histograms for surface and texture description." *Computer Vision and Image Understanding* 125, 2014