
Signed Graph Convolutional Network

School of Industrial and Management Engineering, Korea University

Insung Baek

Contents

- ❖ Research Purpose
- ❖ Proposed Method
- ❖ Experiments
- ❖ Conclusion

Research Purpose

Signed GCN

❖ Signed Graph Convolutional Network (ICDM 2018)

- Michigan State University 에서 연구하였고, 2022년 2월 21일 기준 124회 인용됨
- Node 간 관계성을 반영하기 위해 여러 layer에서 positive link와 negative link의 관계성을 잘 표현하고 통합할 수 있는 Signed Graph Convolutional Network 을 제안함

2018 IEEE International Conference on Data Mining

Signed Graph Convolutional Networks

Tyler Derr

*Data Science and Engineering Lab
Michigan State University
derrtyle@msu.edu*

Yao Ma

*Data Science and Engineering Lab
Michigan State University
mayao4@msu.edu*

Jiliang Tang

*Data Science and Engineering Lab
Michigan State University
tangjili@msu.edu*

Abstract—Due to the fact much of today's data can be represented as graphs, there has been a demand for generalizing neural network models for graph data. One recent direction that has shown fruitful results, and therefore growing interest, is the usage of graph convolutional neural networks (GCNs). They have been shown to provide a significant improvement on a wide range of tasks in network analysis, one of which being node representation learning. The task of learning low-dimensional node representations has shown to increase performance on a plethora of other tasks from link prediction and node classification, to community detection and visualization. Simultaneously, signed


such as link prediction [10], community detection [11], and visualization [12].

Previous work has mostly focused on using GCNs for unsigned graphs (or graphs consisting of only positive links). However, especially with the ever growing popularity of online social media, signed graphs are becoming increasingly ubiquitous. This naturally leads the question as to whether unsigned GCNs are suitable to be used on signed networks. Unfortunately, there are many reasons as to why unsigned

Research Purpose

Research Purpose

- ❖ 이전 Graph Convolutional Network (GCN)는 모두 unsigned graphs이었음 (positive link만)
- ❖ 하지만 위와 같은 GCN은 의미 있는 노드 표현 학습에 한계가 존재함 (negative link 반영X)
- ❖ 본 연구에서는 심리학에서 개발된 기본적인 이론 중 하나인 하이드의 균형이론 (balance theory, 1946)을 기반으로 positive link와 negative link의 복잡한 특성을 잘 통합할 수 있는 방법을 제안함



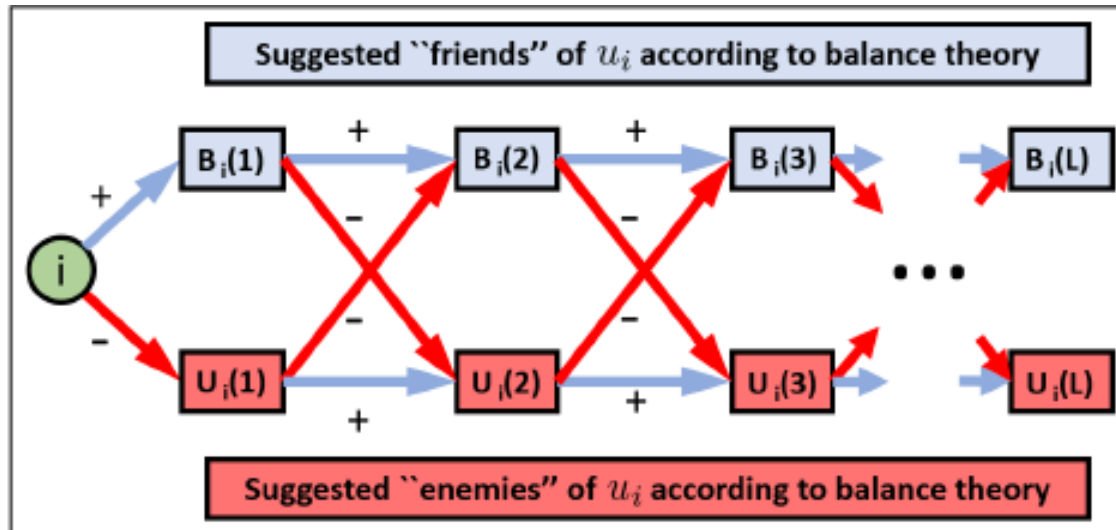
Negative link 개수가
홀수이면
Unbalanced Triangles임

[친구의 친구는 내 친구이고, 친구의 적은 나의 적이다 – 균형 이론]

Proposed Method

Balance theory

- ❖ 심리학에서 제안한 균형 이론(Balance theory)을 기반으로 friends와 enemies를 정의함
- ❖ Negative link 개수가 **짝수**인 경우에는 **friends**, **홀수**인 경우에는 **enemies**로 정의



When $l = 1$

$$B_i(1) = \{u_j \mid u_j \in \mathcal{N}_i^+\}$$

$$U_i(1) = \{u_j \mid u_j \in \mathcal{N}_i^-\}$$

For $l > 1$

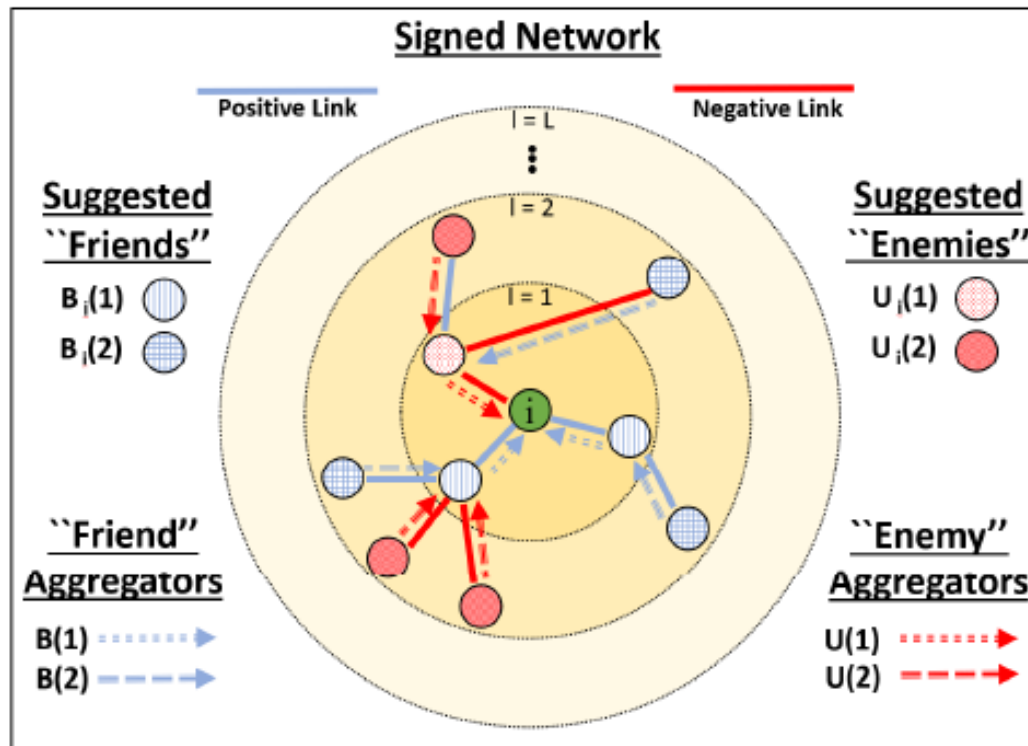
$$B_i(l+1) = \{u_j \mid u_k \in B_i(l) \text{ and } u_j \in \mathcal{N}_k^+\} \\ \cup \{u_j \mid u_k \in U_i(l) \text{ and } u_j \in \mathcal{N}_k^-\}$$

$$U_i(l+1) = \{u_j \mid u_k \in U_i(l) \text{ and } u_j \in \mathcal{N}_k^+\} \\ \cup \{u_j \mid u_k \in B_i(l) \text{ and } u_j \in \mathcal{N}_k^-\}$$

Proposed Method

Signed Network

- ❖ 아래 그림은 균형 이론을 기반으로 Signed Network를 표현한 것임
 - $B(2)$: negative link 개수가 0개 or 2개이므로 "Friends"로 정의됨
 - $U(2)$: negative link 개수가 1개이므로 "Enemies"로 정의됨



Proposed Method

Signed GCN Algorithms

- ❖ 기존 GCN은 Adjacency matrix (Positive link로만 구성)만 사용 했지만, Signed GCN에서는 i번째 node (u_i)에 영향을 주는 positive set (N_i^+)과 negative set (N_i^-)을 함께 고려해서 계산함

Algorithm 1: Typical Unsigned GCN Framework.

Input: An unsigned network adjacency matrix $A \in \mathbb{R}^{n \times n}$; a feature matrix $X \in \mathbb{R}^{n \times d^{in}}$; number of aggregation layers L ; neighborhood aggregation function $f()$

Output: Low-dimensional representation matrix $Z \in \mathbb{R}^{n \times d^{out}}$

```

1  $H^{(0)} \leftarrow X$ 
2 while not convergent do
3   for  $l \in \{0, \dots, L-1\}$  do
4      $H^{(l+1)} \leftarrow f(H^{(l)}, A)$ 
5   end
6   Update GCN parameters based on  $loss(H^{(L)})$ 
7 end
8  $Z \leftarrow H^{(L)}$ 
  
```

Negative link를 반영

Algorithm 2: Signed GCN Embedding Generation.

Input: $\mathcal{G} = (\mathcal{U}, \mathcal{E}^+, \mathcal{E}^-)$; an initial seed node representation $\{x_i, \forall u_i \in \mathcal{U}\}$; number of aggregation layers L ; weight matrices $W^{B(l)}$ and $W^{U(l)}$, $\forall l \in \{1, \dots, L\}$; non-linear function σ

Output: Low-dimensional representations $z_i, \forall u_i \in \mathcal{U}$

```

1  $h_i^{(0)} \leftarrow x_i, \forall u_i \in \mathcal{U}$ 
2 for  $u_i \in \mathcal{U}$  do
3    $h_i^{B(1)} \leftarrow \sigma \left( W^{B(1)} \left[ \sum_{j \in N_i^+} \frac{h_j^{(0)}}{|N_i^+|}, h_i^{(0)} \right] \right)$ 
4    $h_i^{U(1)} \leftarrow \sigma \left( W^{U(1)} \left[ \sum_{k \in N_i^-} \frac{h_k^{(0)}}{|N_i^-|}, h_i^{(0)} \right] \right)$ 
5 end
6 if  $L > 1$  then
7   for  $l = 2 \dots L$  do
8     for  $u_i \in \mathcal{U}$  do
9        $h_i^{B(l)} =$ 
10         $\sigma \left( W^{B(l)} \left[ \sum_{j \in N_i^+} \frac{h_j^{B(l-1)}}{|N_i^+|}, \sum_{k \in N_i^-} \frac{h_k^{U(l-1)}}{|N_i^-|}, h_i^{B(l-1)} \right] \right)$ 
11        $h_i^{U(l)} =$ 
12         $\sigma \left( W^{U(l)} \left[ \sum_{j \in N_i^+} \frac{h_j^{U(l-1)}}{|N_i^+|}, \sum_{k \in N_i^-} \frac{h_k^{B(l-1)}}{|N_i^-|}, h_i^{U(l-1)} \right] \right)$ 
13     end
14   end
15  $z_i \leftarrow [h_i^{B(L)}, h_i^{U(L)}], \forall u_i \in \mathcal{U}$ 
  
```

Proposed Method

Objective Function

- ❖ Signed network의 임베딩 공간에서 node간 관계성을 잘 학습하기 위한 목적함수를 제안
 - **First term:** a weighted multinomial logistic regression classifier. (한 쌍의 노드 임베딩 사이의 link 관계)
 - **Second term:** 균형 이론에 기반한 term으로 positive link 관계인 node는 no link보다 가깝고, no link 관계인 node는 negative link보다는 가깝게 학습하도록 유도 (λ 로 기여도를 조절함)

$$\begin{aligned} \mathcal{L}(\theta^W, \theta^{MLG}) = & -\frac{1}{\mathcal{M}} \sum_{(u_i, u_j, s) \in \mathcal{M}} \omega_s \log \frac{\exp([z_i, z_j] \theta_s^{MLG})}{\sum_{q \in \{+, -, ?\}} \exp([z_i, z_j] \theta_q^{MLG})} \\ & + \lambda \left[\frac{1}{|\mathcal{M}_{(+, ?)}|} \sum_{\substack{(u_i, u_j, u_k) \\ \in \mathcal{M}_{(+, ?)}}} \max \left(0, (\|z_i - z_j\|_2^2 - \|z_i - z_k\|_2^2) \right) \right. \\ & \left. + \frac{1}{|\mathcal{M}_{(-, ?)}|} \sum_{\substack{(u_i, u_j, u_k) \\ \in \mathcal{M}_{(-, ?)}}} \max \left(0, (\|z_i - z_k\|_2^2 - \|z_i - z_j\|_2^2) \right) \right] \\ & + \text{Reg}(\theta^W, \theta^{MLG}) \end{aligned} \quad (7)$$

Regularization Term

Results

Dataset

- ❖ 아래 4가지 데이터는 모두 positive, negative link를 정의할 수 있음
- ❖ Bitcoin-Alpha, Bitcoin-OTC 데이터는 edge 가중치가 -10부터 10까지 존재함 (가중치의 부호를 기반으로 positive, negative link를 정의)
- ❖ Slashdot 사용자가 서로 간 긍정/부정을 만들 수 있는 뉴스 사이트에서 기반한 데이터임
- ❖ Epinions 제품 리뷰 웹사이트로, 사용자는 다른 사용자를 신뢰/불신하는 사용자로 분류

TABLE II
STATISTICS OF FOUR SIGNED SOCIAL NETWORKS.

Network	# Users	# Positive Links	# Negative Links
Bitcoin-Alpha	3,784	12,729	1,416
Bitcoin-OTC	5,901	18,390	3,132
Slashdot	33,586	295,201	100,802
Epinions	16,992	276,309	50,918

Results

Results table

- ❖ AUC, F1 모두 제안한 Signed GCN (SGCN-2)이 가장 성능이 좋았음을 확인
- ❖ SGCN-1: 인접한 link 정보만 사용 (positive/negative link만 활용, aggregator layer 1개)
- ❖ SGCN-1+: 인접한 link 정보를 2번 활용해서 사용 (균형 이론 사용하지 않음)
- ❖ SGCN-2: 본 연구에서 제안한 균형 이론 기반 방법론을 적용

TABLE III
LINK SIGN PREDICTION RESULTS WITH AUC.

Embedding Method	Bitcoin-Alpha	Bitcoin-OTC	Slashdot	Epinions
SSE	0.764	0.803	0.769	0.822
SiNE	0.778	0.814	0.792	0.849
SIDE	0.630	0.618	0.547	0.571
SGCN-1	0.780	0.818	0.784	0.663
SGCN-1+	0.785	0.817	0.804	0.722
SGCN-2	0.796	0.823	0.804	0.864

TABLE IV
LINK SIGN PREDICTION RESULTS WITH F1.

Embedding Method	Bitcoin-Alpha	Bitcoin-OTC	Slashdot	Epinions
SSE	0.898	0.923	0.820	0.901
SiNE	0.888	0.878	0.854	0.914
SIDE	0.738	0.750	0.646	0.711
SGCN-1	0.910	0.918	0.853	0.851
SGCN-1+	0.912	0.923	0.865	0.893
SGCN-2	0.917	0.925	0.864	0.933

Conclusion

❖ Conclusion

- 기존 GCN은 node간 연결이 0 또는 1로 표현되어, node간 관계가 positive link 또는 no link로만 표현된다는 한계점이 존재함
- 하지만 현실 문제에서는 두 node간 관계가 부정적인 경우도 존재하기 때문에 negative link를 적용할 수 있는 방법론이 필요함
- 본 연구에서는 여러 node의 복잡한 positive, negative link 관계를 잘 통합해서 적용하기 위해 심리학에서 제안되었던 균형 이론 (balance theory)을 기반한 Signed GCN을 제안함
- 총 4개의 실제 현실 데이터에 적용해서 Signed GCN의 효용성을 증명함
- 실제 현실 문제의 다양하고 복잡한 node간 관계를 파악하고 그 정보를 활용하기 위해서는 Signed GCN의 접근 방법이 용이하다고 생각함

Thank You

Appendix

Appendix

Reference

- ❖ Derr, T., Ma, Y., & Tang, J. (2018, November). Signed graph convolutional networks. In 2018 IEEE International Conference on Data Mining (ICDM) (pp. 929-934). IEEE.
- ❖ <https://blog.naver.com/soulhole/220886028171>