
Boosting Contrastive Self-Supervised Learning with False Negative Cancellation

School of Industrial and Management Engineering, Korea University

Jinsoo Bae

Contents

- ❖ Research Purpose
- ❖ Boosting Contrastive Learning Using False Negative Cancellation
- ❖ Experiments
- ❖ Conclusion

Research Purpose

- ❖ Boosting Contrastive Self-Supervised Learning with False Negative Cancellation (WACV, 2022)
 - Google에서 연구하였으며 2022년 6월 6일 기준으로 20회 인용
 - Contrastive Learning의 **Negative 데이터 선정 방법을 개선시킨 것이 핵심**

Boosting Contrastive Self-Supervised Learning with False Negative Cancellation

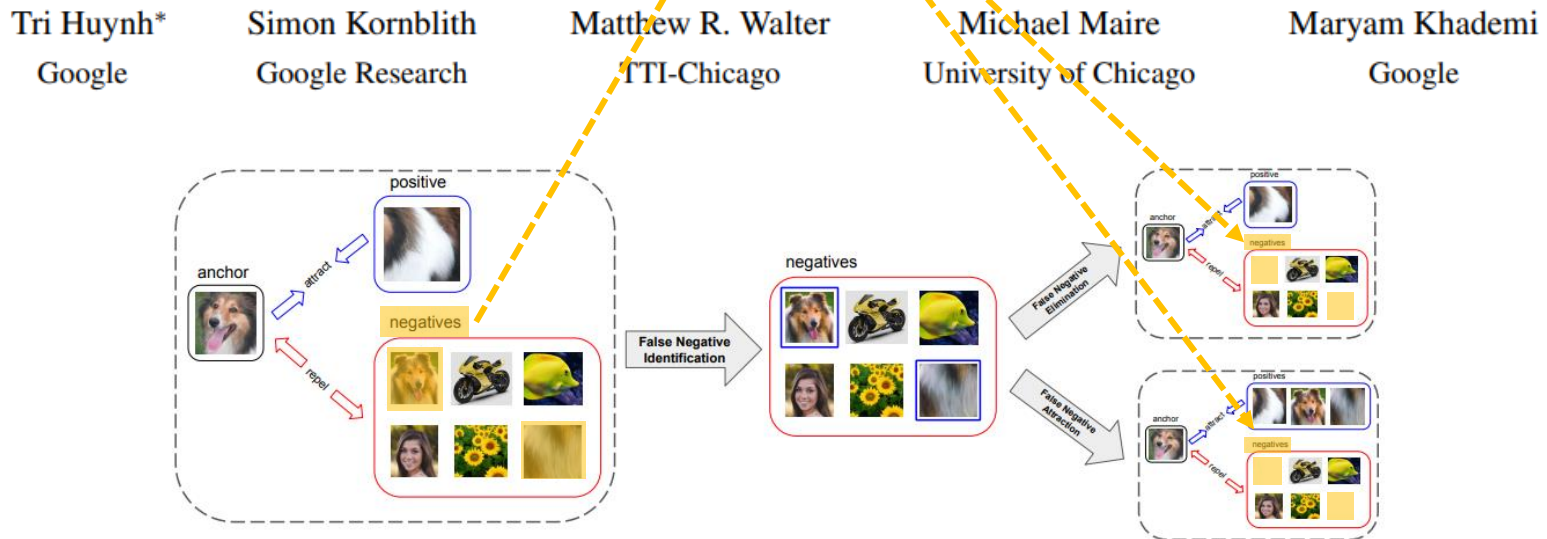


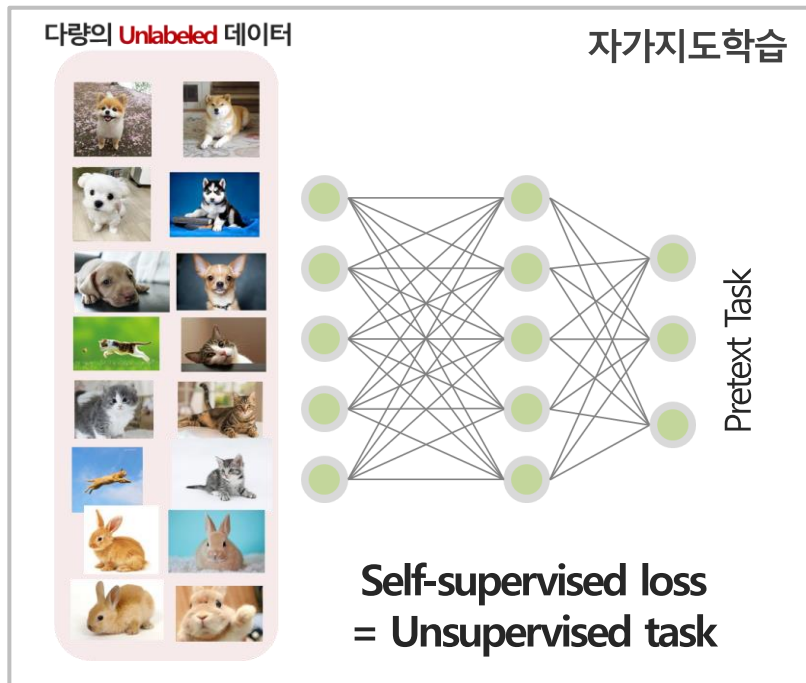
Figure 2. Overview of the proposed framework. **Left:** Original definition of the anchor, positive, and negative samples in contrastive learning. **Middle:** Identification of false negatives (blue). **Right:** false negative cancellation strategies, i.e. elimination and attraction.

Research Purpose

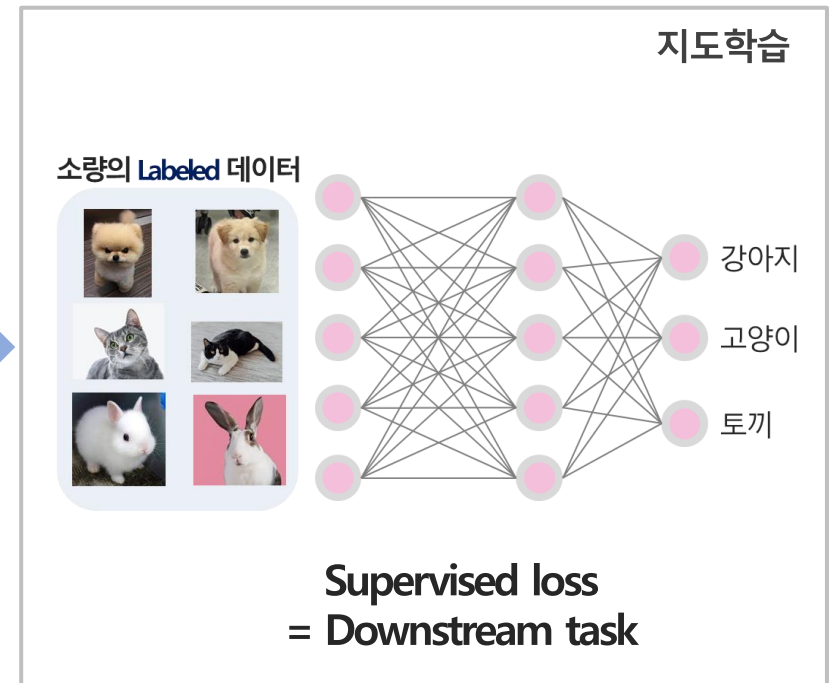
❖ Contrastive Self-Supervised Learning in Computer Vision

- 대조학습은 다량의 Unlabeled 데이터로부터 유의미한 데이터 특징 학습을 수행 (stage 1)
- 대조학습 수행 후 소량의 Labeled 데이터로 Downstream task 해결 학습 진행 (stage 2)
- 대조학습을 통해 Labeled 데이터가 충분치 않을 때에도 효과적인 Downstream task 해결 가능

Stage 1




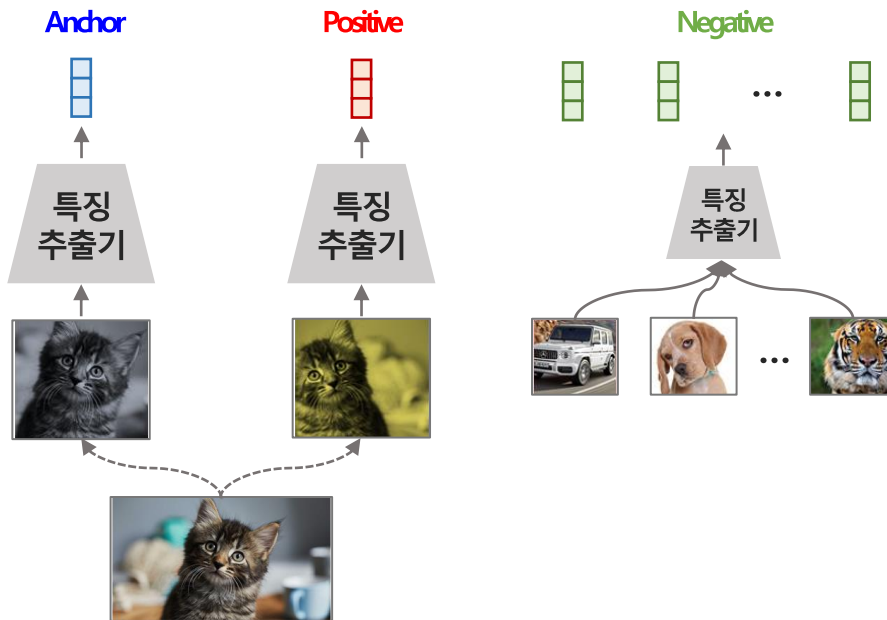
Stage 2



Research Purpose

❖ Contrastive Self-Supervised Learning in Computer Vision


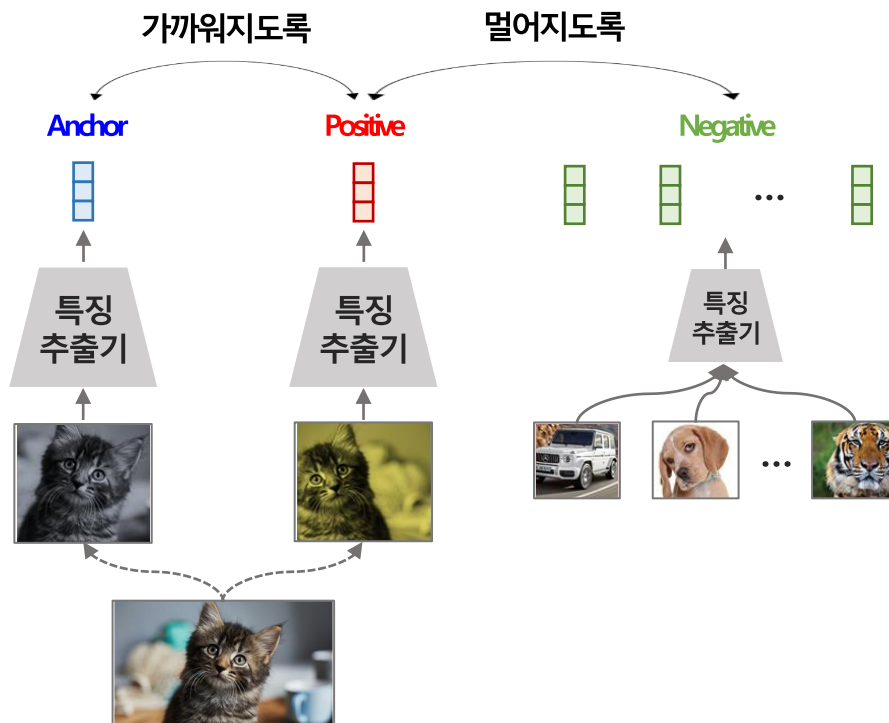
1. 한 이미지에 두 종류 이상의 데이터 증강 기법을 적용해 **Anchor**, **Positive** 데이터를 생성함
2. 한 이미지를 제외한 나머지 모든 데이터들을 **Negative** 데이터로 정의함



Research Purpose

❖ Contrastive Self-Supervised Learning in Computer Vision

3. 비슷한 데이터들의(**Anchor**, **Positive**) 특징이 유사해지도록 (Feature Space상에서 Feature가 가까워지도록)
4. 그 외의 데이터(**Negative**) 특징이 다르도록 학습 (Feature Space상에서 Feature가 멀어지도록)



Anchor와 **Positive**는 가까워지도록 학습

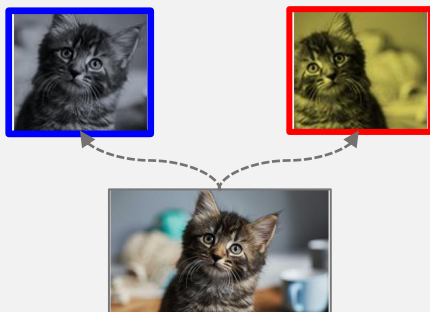
Anchor와 **Negative**는 멀어지도록 학습

Research Purpose

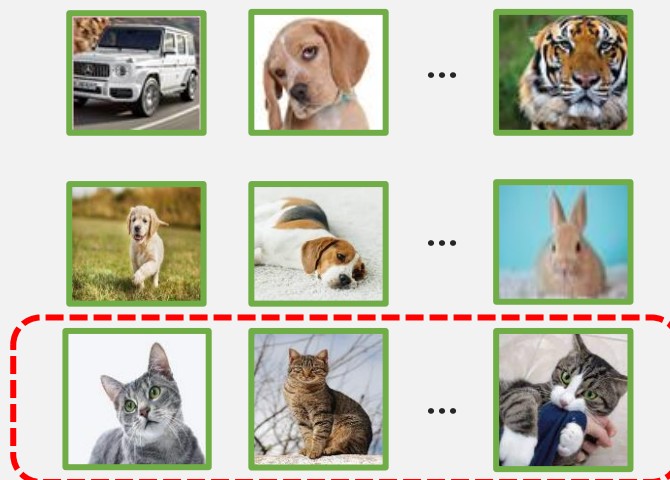
❖ False Negative Examples in Contrastive Learning

- Anchor, Positive 데이터 생성 시 사용된 데이터를 제외하고, 나머지 모든 데이터들을 Negative로 간주하는 기존 방법론들의 Negative 선정 방법이 과연 옳은 걸까, 본 연구에서 의문을 던짐
- 기존 Negative 데이터들 내에도 Anchor 데이터와 비슷한 데이터들이 포함되어 있을 수 있다!

기존 방식에 의한 **Anchor**,
Positive 데이터 선정 결과



기존 방식에 의한 **Negative**
데이터 선정 결과

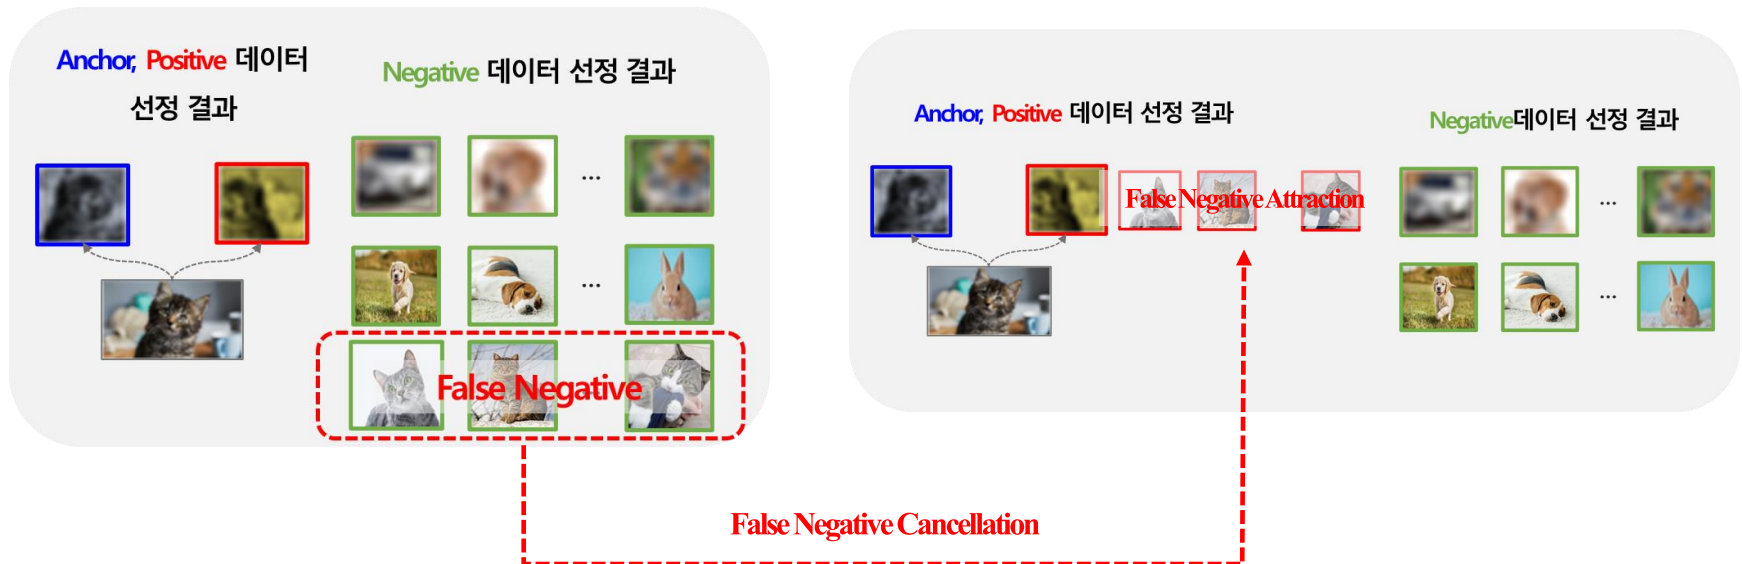


대조학습에 악영향을 끼치는
False Negative 데이터

Research Purpose

❖ False Negative Examples in Contrastive Learning

- 기존 Negative 데이터들 가운데, False Negative 데이터를 제거해 올바른 Negative samples를 만들자
- False Negative 데이터를 Positive 데이터로 변경하여 Positive samples를 늘리자
- 결론은 Positive, Negative 데이터 선정을 이전보다 더 올바르게 하여 대조학습의 효과를 올리자!
- 본 연구는 효과적인 False Negative 데이터 탐지 및 활용 방법에 대해 연구함




Boosting Contrastive Learning Using False Negative Cancellation

❖ False Negative 탐지를 위한 가정사항(Ideation) 두 가지

1. False Negative 데이터는 Original data와 반드시 **공통된 특징을 하나 갖고 있음** (ex: Dog)
2. False Negative 데이터는 Original data에 여러 증강 기법을 적용한 데이터들 중 **하나와 공통된 특징을 갖고 있음** (ex: Dog's Head, Orientation)

Original data i





증강 기법 1 적용
(Main views)



증강 기법 2 적용
(Support views)

False Negative data m



증강 기법 1 적용
(Main views)

Boosting Contrastive Learning Using False Negative Cancellation


❖ False Negative 탐지를 위한 가정사항(Ideation) 두 가지

1. False Negative 데이터는 Original data와 반드시 **공통된 특징을 하나 갖고 있음** (ex: Dog)
2. False Negative 데이터는 Original data에 여러 증강 기법을 적용한 데이터들 중 **하나와 공통된 특징을 갖고 있음** (ex: Dog's Head, Orientation)

Original data i



개라는 공통된 특징을 갖고 있으나,
얼굴 각도 관점에서는 특징 불일치





증강 기법 1 적용
(Main views)



증강 기법 2 적용
(Support views)

False Negative data m



증강 기법 1 적용
(Main views)

Boosting Contrastive Learning Using False Negative Cancellation

❖ False Negative 탐지를 위한 가정사항(Ideation) 두 가지

1. False Negative 데이터는 Original data와 반드시 **공통된 특징을 하나 갖고 있음** (ex: Dog)
2. False Negative 데이터는 Original data에 여러 증강 기법을 적용한 데이터들 중 **하나와 공통된 특징을 갖고 있음** (ex: Dog's Head, Orientation)


Original data i




데이터 m 은 데이터 i 의 False Negative

개라는 공통된 특징을 갖고 있고,
얼굴 각도 관점에서도 공통된 특징


False Negative data m



증강 기법 1 적용
(Main views)



증강 기법 2 적용
(Support views)



증강 기법 1 적용
(Main views)

Boosting Contrastive Learning Using False Negative Cancellation

❖ 데이터 i 의 False Negative 데이터 탐지 방법

1. For each anchor i , generate a support set $\mathbb{S}_i = \{z_i^s\}$ that contains other support views from the same image besides the two main views.

→ 데이터 i 에 증강 기법을 적용한 데이터 z_i^s 들의 집합 \mathbb{S}_i 생성
2. Compute similarity scores, $\text{score}_{m,i}^s = \text{sim}(z_m, z_i^s)$, between a negative sample z_m and each sample z_i^s in the support set.

→ 데이터 m 과 집합 \mathbb{S}_i 사이의 모든 원소들과 코사인 유사도를 산출
→ 코사인 유사도 집합 산출
3. Aggregate the computed scores for each negative sample, $\text{score}_{m,i} = \text{aggregate}_{s \in \mathbb{S}}(\text{score}_{m,i}^s)$.

→ 코사인 유사도 집합 원소들 중 대표값을 (평균 혹은 최대) 선정하여 데이터 i 와 m 사이의 유사도 스코어 $\text{score}_{m,i}$ 정의
4. Define a set of potential false negatives \mathbb{F}_i as the negative samples that are most similar to the support set based on the aggregated scores, $\mathbb{F}_i = \text{best}(\text{score}_i)$, where $\text{score}_i = \{\text{score}_{m,i} | m\}$ is the set of scores for each negative sample with respect to anchor i .

→ 큰 $\text{score}_{m,i}$ 값을 가진 데이터 포인트 m 을 i 의 False Negative 데이터로 최종 의사결정

아래 두가지 방식중 하나를 선택 혹은 병합하여 선택

 - $\text{score}_{m,i}$ 기준 TopK를 False Negative 선정
 - $\text{score}_{m,i}$ 기준 특정 임계값 τ 이상 데이터를 False Negative 선정

Boosting Contrastive Learning Using False Negative Cancellation

❖ False Negative 데이터 탐지 후 → False Negative Elimination or Attraction

- False Negative 데이터들을 Negative samples 사이에서 제거만 하는 경우 False Negative Elimination
- 제거된 False Negative 데이터들을 Positive samples에 추가하는 경우 False Negative Attraction
- 본 연구는 여러가지 실험 조건에 대해 Elimination과 Attraction의 효과들을 검증하였음

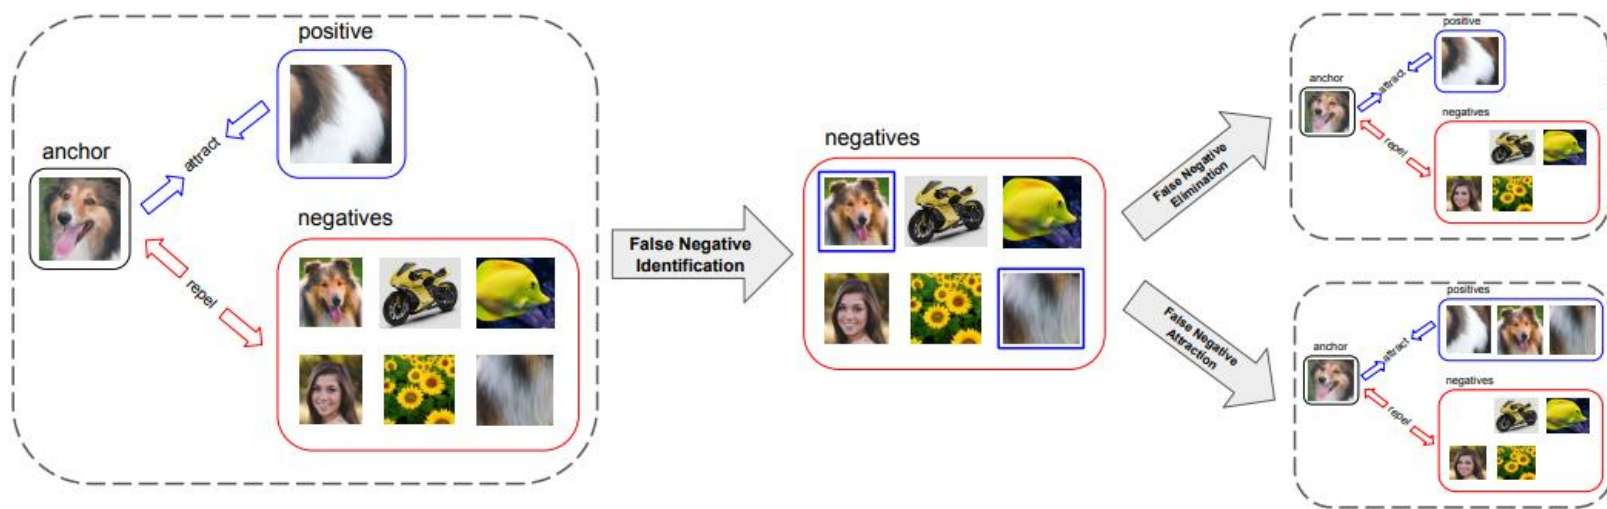


Figure 2. Overview of the proposed framework. **Left:** Original definition of the anchor, positive, and negative samples in contrastive learning. **Middle:** Identification of false negatives (blue). **Right:** false negative cancellation strategies, *i.e.* elimination and attraction.

Boosting Contrastive Learning Using False Negative Cancellation

❖ Contrastive Self-Supervised Learning Loss Using False Negative Detection

1) 기존 Contrastive Learning Loss

→ 자기 자신을 제외한 나머지 모든 데이터들을 Negative Samples로 간주함

2) False Negative 데이터들을 Negative samples 사이에서 제거만 하는 경우 False Negative Elimination

3) 제거된 False Negative 데이터들을 Positive samples에 추가하는 경우 False Negative Attraction

$$l_i = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^M \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (1)$$

$$l_i^{\text{elim}} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i, k \notin \mathbb{F}_i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (2)$$

$$l_i^{\text{att}} = -\frac{1}{1 + |\mathbb{F}_i|} \left(\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} + \sum_{f \in \mathbb{F}_i} \log \frac{\exp(\text{sim}(z_i, z_f)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \right) \quad (3)$$

Boosting Contrastive Learning Using False Negative Cancellation

❖ Contrastive Self-Supervised Learning Loss Using False Negative Detection

- 1) 기존 Contrastive Learning Loss
- 2) False Negative 데이터들을 Negative samples 사이에서 제거만 하는 경우 False Negative Elimination
→ 자기 자신 및 False Negative Samples F_i 를 제외한 나머지 데이터들을 Negative Samples로 간주
- 3) 제거된 False Negative 데이터들을 Positive samples에 추가하는 경우 False Negative Attraction

$$l_i = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^M \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (1)$$

$$l_i^{\text{elim}} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i, k \notin F_i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (2)$$

$$l_i^{\text{att}} = -\frac{1}{1 + |F_i|} \left(\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} + \sum_{f \in F_i} \log \frac{\exp(\text{sim}(z_i, z_f)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \right) \quad (3)$$

Boosting Contrastive Learning Using False Negative Cancellation

❖ Contrastive Self-Supervised Learning Loss Using False Negative Detection

- 1) 기존 Contrastive Learning Loss
- 2) False Negative 데이터들을 Negative samples 사이에서 제거만 하는 경우 False Negative Elimination
- 3) 제거된 False Negative 데이터들을 Positive samples에 추가하는 경우 False Negative Attraction
 - 자기 자신을 augmentation한 데이터와 False Negative Samples F_i 들을 Positive Samples로 간주
 - 자기 자신을 제외한 나머지 모든 데이터들을 Negative Samples로 간주함

$$l_i = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^M \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (1)$$

$$l_i^{\text{elim}} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i, k \notin F_i]} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (2)$$

$$l_i^{\text{att}} = -\frac{1}{1 + |F_i|} \left(\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} + \sum_{f \in F_i} \log \frac{\exp(\text{sim}(z_i, z_f)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \right) \quad (3)$$

Experiments (Encoder Freeze & Linear Evaluation)

False Negative Cancellation Strategies

- ❖ False Negative 제거는 데이터 Crop size 크기에 상관없이 일관된 성능 향상을 보여주었고, Crop size 크기가 클수록 더 높은 성능 향상을 보였음
 - 데이터 Crop의 경우 기존 Contrastive Learning에서 자주 사용하는 데이터 증강 기법 중 하나
 - 한 데이터 포인트 당 2개의 False Negative 데이터를 선별하여 제거한 경우임 (왼쪽, Top K=2)




Figure 4. A comparison of top-1 accuracy (left) between false negative elimination and SimCLR (*lower bound of random crop ratio* represents the lowest cropping ratio in random image augmentation); and (right) top-1 accuracy across filtering thresholds in false negative cancellation.

Experiments (Encoder Freeze & Linear Evaluation)

False Negative Cancellation Strategies

- ❖ Support set 활용(= False Negative Samples 판별 시, 두 종류 이상의 데이터 증강 기법을 적용한 것을 의미)을 통해, SimCLR 대비 더 높은 성능 향상을 이뤄냄
 - 저자들이 제안하였던 두 번째 가정사항이 False Negative 데이터 탐지에 효과적임을 알 수 있음




Figure 5. False negative cancellation with and without support set across top- k choices for different mitigation strategies. The dashed line denotes the performance of the SimCLR baseline. The results use mean aggregation in scoring potential false negatives.

Experiments (Encoder Freeze & Linear Evaluation)

False Negative Cancellation Strategies

- ❖ Support set의 코사인 유사도 대표값 선정 방식에는 평균과 최댓값이 있으며, 이 방법에 따라서도 유의미한 성능 차이가 존재하였음
 - False Negative Attraction의 경우 최댓값 방식이 유의미하게 더 좋은 성능 향상을 보여주었음

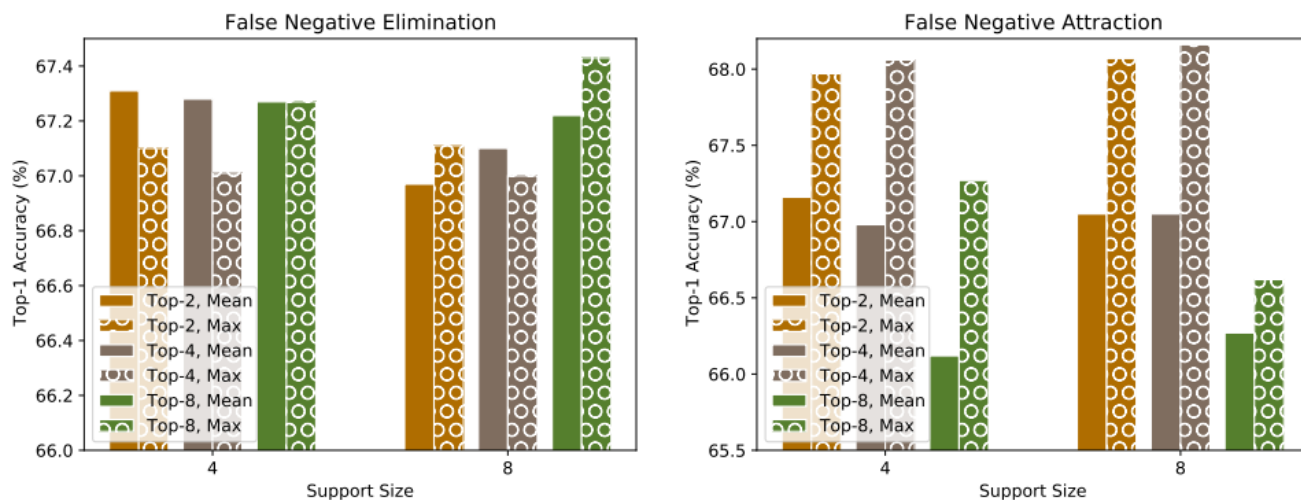


Figure 6. False negative cancellation with mean and max aggregation across support sizes and top- k for the false negative (left) elimination and (right) attraction strategies.

Experiments

False Negative Cancellation Strategies

- ❖ Feature Extraction 결과, 비교 방법론(SimCLR v2) 대비 클래스 간 더 유의미한 구분이 형성되는 것을 확인 → 더 유의미한 특징 학습을 수행한 것을 확인할 수 있음

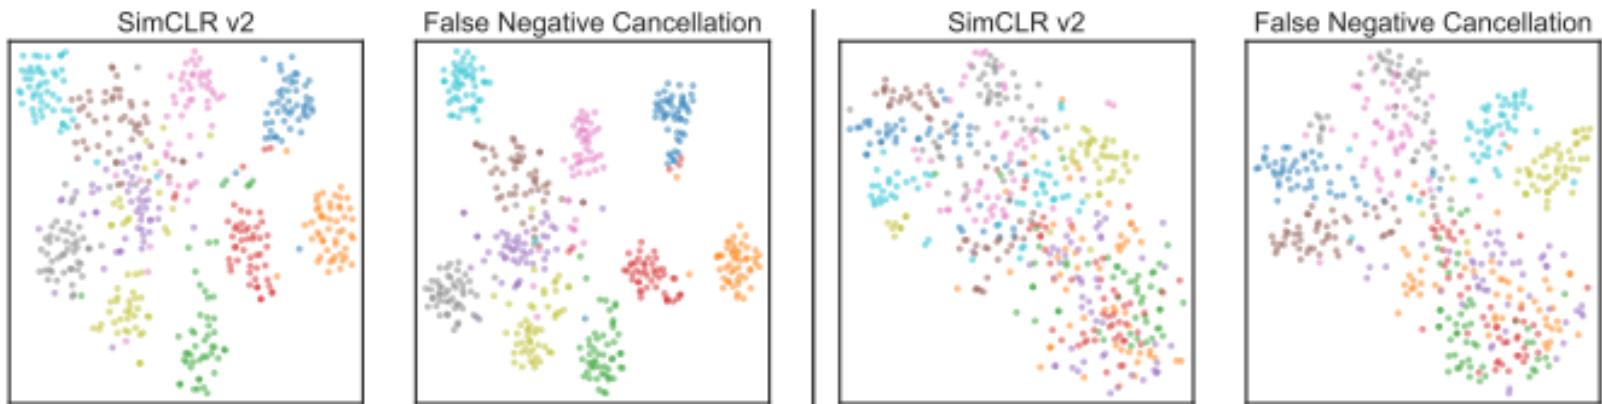


Figure 11. t-SNE visualizations of SimCLR and FNC for 10 random classes (left) and 10 dog classes (right) from ImageNet.

Experiments

False Negative Cancellation Strategies (FNC)

- ❖ Table 5: Encoder freeze, a linear classifier training → 비교 방법론 대비 가장 우수한 성능
- ❖ Table 6: Both Encoder and a linear classifier training → 비교 방법론 대비 가장 우수한 성능

Method	top-1	top-5
Supervised	76.5	
<i>Representation Learning</i>		
<i>Contrastive learning</i>		
MoCo v1 [24]	60.6	—
PIRL [35]	63.6	—
PCL [33]	65.9	—
SimCLR v1 [9]	69.3	89.0
MoCo v2 [11]	71.1	—
SimCLR v2 [10]	71.7	90.4
InfoMin [44]	73.0	91.1
FNC (ours)	74.4	91.8
<i>Others</i>		
BYOL [23]	74.3	91.6
SwAV [7]	75.3	—

Table 5. ImageNet linear evaluation.

Method	1%		10%	
	top-1	top-5	top-1	top-5
Supervised	25.4	56.4	48.4	80.4
<i>Semi-supervised</i>				
UDA [51]	—	68.8	—	88.5
FixMatch [42]	—	71.5	—	89.1
<i>Representation Learning</i>				
<i>Contrastive learning</i>				
PIRL [35]	30.7	60.4	57.2	83.8
PCL [33]	—	—	75.6	86.2
SimCLR v1 [9]	48.3	75.5	65.6	87.8
SimCLR v2 [10]	57.9	82.5	68.4	89.2
FNC (ours)	63.7	85.3	71.1	90.2
<i>Others</i>				
BYOL [23]	53.2	78.4	68.8	89.0
SwAV [7]	53.9	78.5	70.2	89.9

Table 6. ImageNet semi-supervised evaluation.

Conclusion

❖ Conclusion

- 기존 Contrastive Learning 방법론들의 Negative Samples 선정 방법을 심층적으로 개선시킨 첫 논문
- 잘못된 False Negative 데이터 제거만으로도 유의미한 성능 향상을 일으킬 수 있었음
- 특히, 한 데이터 당 2개 정도의 False Negative 데이터 제거로도 약 1%의 유의미한 성능 향상
- 향후 여러 가지의 Contrastive Learning 방법들에 범용적으로 적용 가능함

Thank You