

---

# Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

---

School of Industrial and Management Engineering, Korea University

Sae Rin Lim

# • Contents

---

1. Introduction
2. Quantifying Alignment and Uniformity
3. Experiments
4. Summary & Conclusions

# • Introduction

---

## ❖ Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

- 2020 ICML에 게재, 2022년 06월 09일 기준 377회 인용
- Contrastive learning의 표현학습에 대한 새로운 insight를 제공하는 논문
- Contrastive loss의 역할을 Unit hypersphere상에서 학습되는 normalized representation vector들의 Alignment와 Uniformity의 관점에서 해석(contrastive learning을 설명할 때 많이 쓰이는 attract, repel 개념)

---

## Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere


---

Tongzhou Wang<sup>1</sup> Phillip Isola<sup>1</sup>

# • Introduction

## ❖ Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

- 많은 방법론에서  $l_2$ -normalized representation을 통해 embedding 공간을 unit hypersphere 로 제한
- 이러한 방법을 통해서 학습의 안정성을 향상시키고 각 클래스 별로 linearly separable한 representation을 학습하게 함
- 이 때, 학습되는 representation은 불필요한 디테일에 불변해야 하며 가능한 많은 정보를 보존해야 한다고 주장

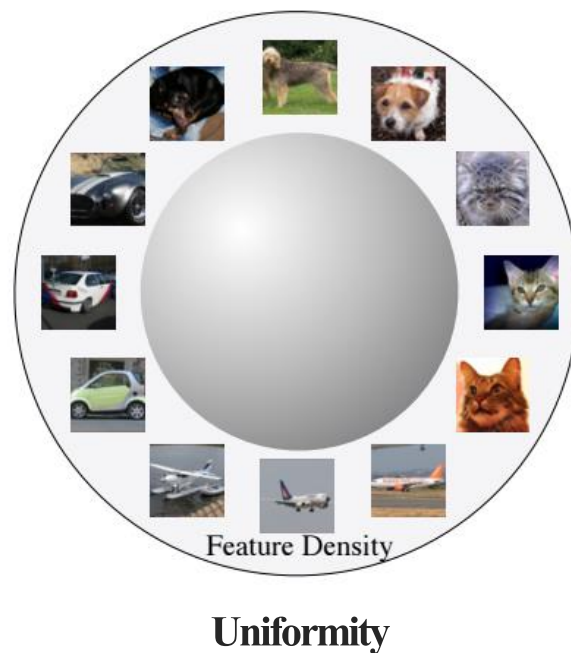
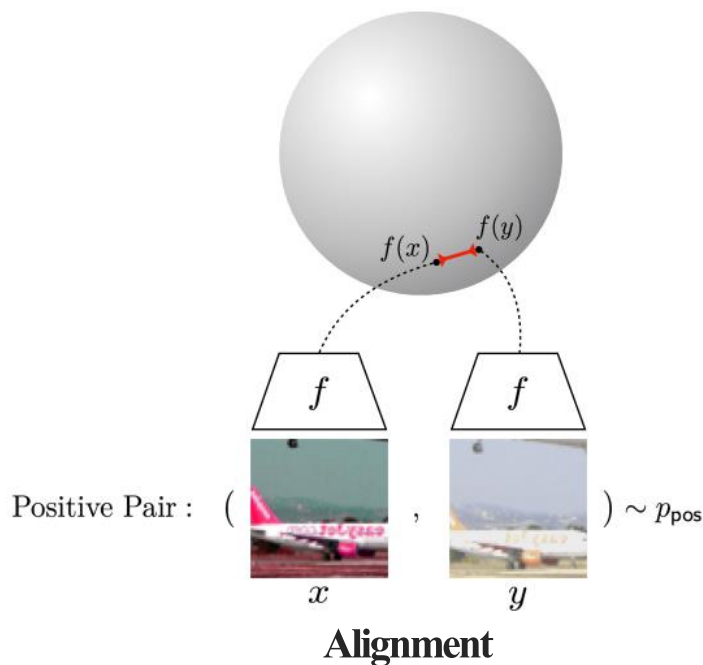


**Well-clustered classes are linearly separable**

# • Introduction

## ❖ Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

- 저자들은 이러한 특성을 **Alignment**와 **Uniformity**로 정의
- Alignment** : Unit hypersphere 상에서 positive pair 간의 가까움 정도로 비슷한 샘플은 비슷한 representation으로 mapping할수록 좋은 encoder
- Uniformity** : Unit hypersphere 상에서 학습된 normalized representation vector 분포의 균일성으로 균일하게 분포되게 mapping할수록 좋은 encoder



# • Introduction

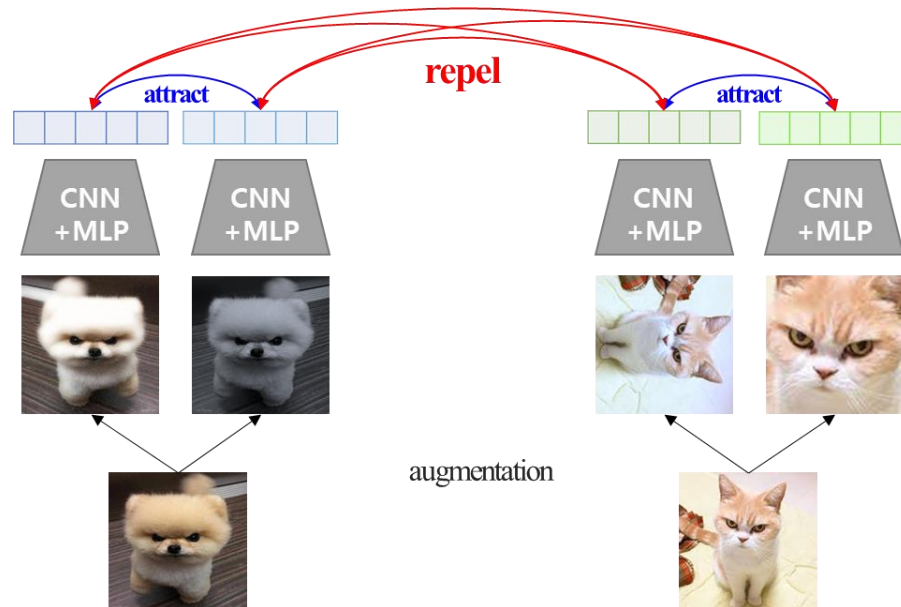
## ❖ Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

- Contrastive representation learning은 augmentation을 통해 positive pair sample을 만들고 unit hypersphere 상에서 **positive pair**는 가까이 **negative samples**와는 멀도록 학습이 진행

$$\mathcal{L}_{\text{contrastive}}(f; \tau, M) \triangleq$$

$$\mathbb{E}_{\substack{(x,y) \sim p_{\text{pos}} \\ \{x_i^-\}_{i=1}^M \stackrel{\text{i.i.d.}}{\sim} p_{\text{data}}}} \left[ -\log \frac{e^{f(x)^T f(y)/\tau}}{e^{f(x)^T f(y)/\tau} + \sum_i e^{f(x_i^-)^T f(y)/\tau}} \right]$$

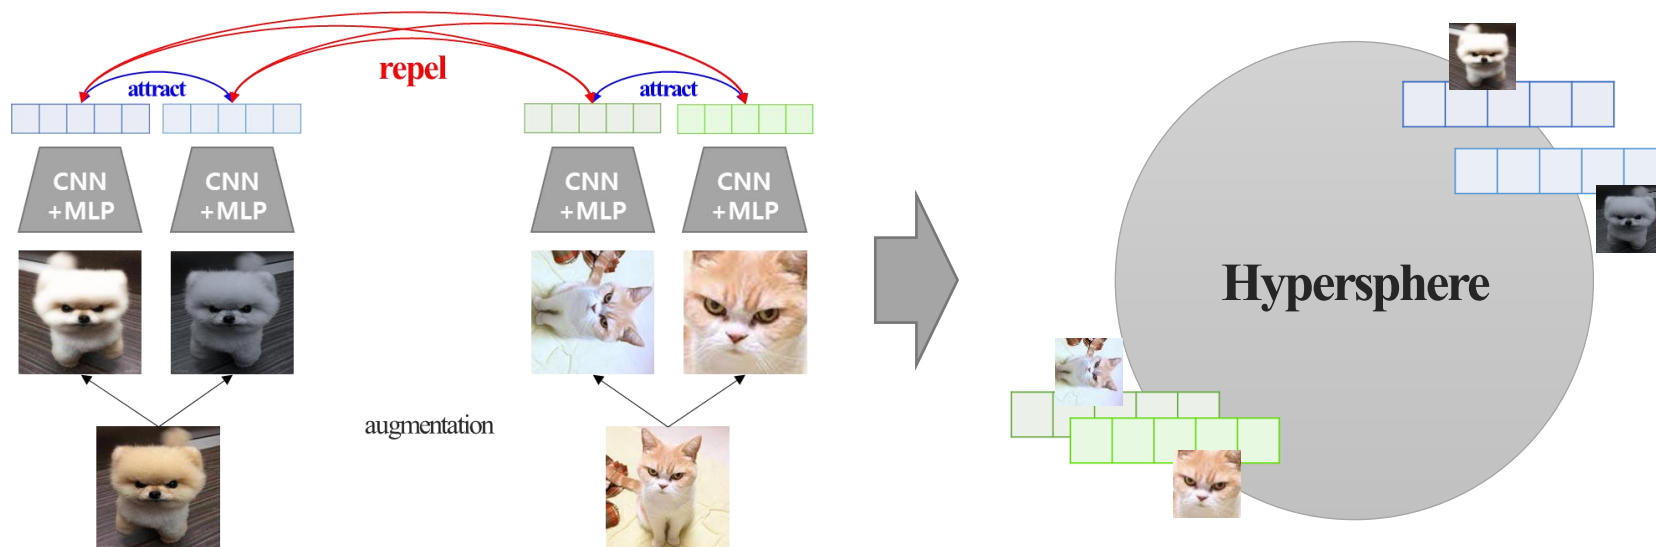
- Loss를 최소화 하기 위해서 **Positive**의 유사도는 커져야 하기 때문에 unit hypersphere에서 가까워짐 (**attract**)
- 반대로 **Negative**와의 유사도는 적어져야 하기 때문에 멀어짐 (**repel**)



# • Introduction

## ❖ Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere

- 저자들은 Contrastive learning을 통해 학습되는 representation이 **alignment**와 **uniformity**를 최대화하는 방향으로 학습된다고 주장
- 이 두 특성에 대한 지표가 downstream task의 성능과 연관이 있음을 보임
- contrastive loss가 아닌 **alignment**와 **uniformity**을 직접 최적화하는 것이 더 효과적일 수 있음을 보임



# • Quantifying Alignment and Uniformity

## ❖ Relationship between Contrastive Loss, Alignment, and Uniformity

- Contrastive loss를 변형하여 **Alignment**와 **Uniformity**의 관계를 확인
- **식 (2)**는 항상 양수 (거리  $\geq 0$ )이기 때문에 목적함수를 최소화 하기 위해서 **식 (1)**이 줄어들음
- 즉, **positive pair**인  $x$ 와  $y$ 의 코사인 유사도  $f(x)^T f(y)$ 가 1에 가까워지도록 학습 (Alignment 최적화)
- **식 (1)**이 완벽하게 최적화되어  $f(x)^T f(y) = 1$ 이 되었다면 **식 (3)**을 최소화하도록 학습
- 즉, **Negative** ( $x_i^-$ )와의 유사도  $f(x)^T f(x_i^-)$ 가 0에 가까워지도록 학습 (Uniformity 최적화)

$$\begin{aligned}\mathcal{L}_{\text{contrastive}}(f; \tau, M) &\triangleq \\ &\mathbb{E}_{\substack{(x, y) \sim p_{\text{pos}} \\ \{x_i^-\}_{i=1}^M \stackrel{\text{i.i.d.}}{\sim} p_{\text{data}}}} \left[ -\log \frac{e^{f(x)^T f(y)/\tau}}{e^{f(x)^T f(y)/\tau} + \sum_i e^{f(x_i^-)^T f(y)/\tau}} \right] \\ &= \mathbb{E}_{(x, y) \sim p_{\text{pos}}} [-f(x)^T f(y)/\tau] \quad (1)\end{aligned}$$


$$+ \mathbb{E}_{\substack{(x, y) \sim p_{\text{pos}} \\ \{x_i^-\}_{i=1}^M \stackrel{\text{i.i.d.}}{\sim} p_{\text{data}}}} \left[ \log \left( e^{f(x)^T f(y)/\tau} + \underbrace{\sum_i e^{f(x_i^-)^T f(x)/\tau}}_{(3)} \right) \right] \quad (2)$$




# • Quantifying Alignment and Uniformity

## ❖ Embedding Space Visualization


- Contrastive learning으로 형성되는 embedding representation이 **alignment**와 **uniformity**를 최적화하는 방향으로 학습이 된다는 것을 증명하기 위해 CIFAR-10 데이터를 2차원으로 임베딩하여 시각화
- Contrastive learning으로 학습된 임베딩 공간에서 비슷한 샘플끼리 군집화되며 분포도 가장 균일함



(a) Random Initialization. Linear classification validation accuracy: 12.71%.



(b) Supervised Predictive Learning. Linear classification validation accuracy: 57.19%.



(c) Unsupervised Contrastive Learning. Linear classification validation accuracy: 28.60%.

**Uniformity**

- Representation의 분포가 균일함

**Alignment**

- 비슷한 샘플끼리 가까이 존재

# • Quantifying Alignment and Uniformity

## ❖ Quantification

- 더 고차원일 경우에도 contrastive learning이 **alignment**와 **uniformity**를 최적화 하도록 학습한다는 것을 증명하기 위해서 저자들은 이 두 특성을 정량화 함

- **Alignment**는 두 샘플 간 거리로 정의

- **Uniformity**는 Gaussian potential kernel (a.k.a RBF kernel)을 통해서 정의

\*커널은 두 샘플의 변환된 벡터의 내적을 출력해주는 함수로 내적이기 때문에 두 벡터가 동일할 때 가장 크고 거리가 멀어질수록 값이 작아짐

$$k(x, y) = \phi(x) \cdot \phi(y)$$

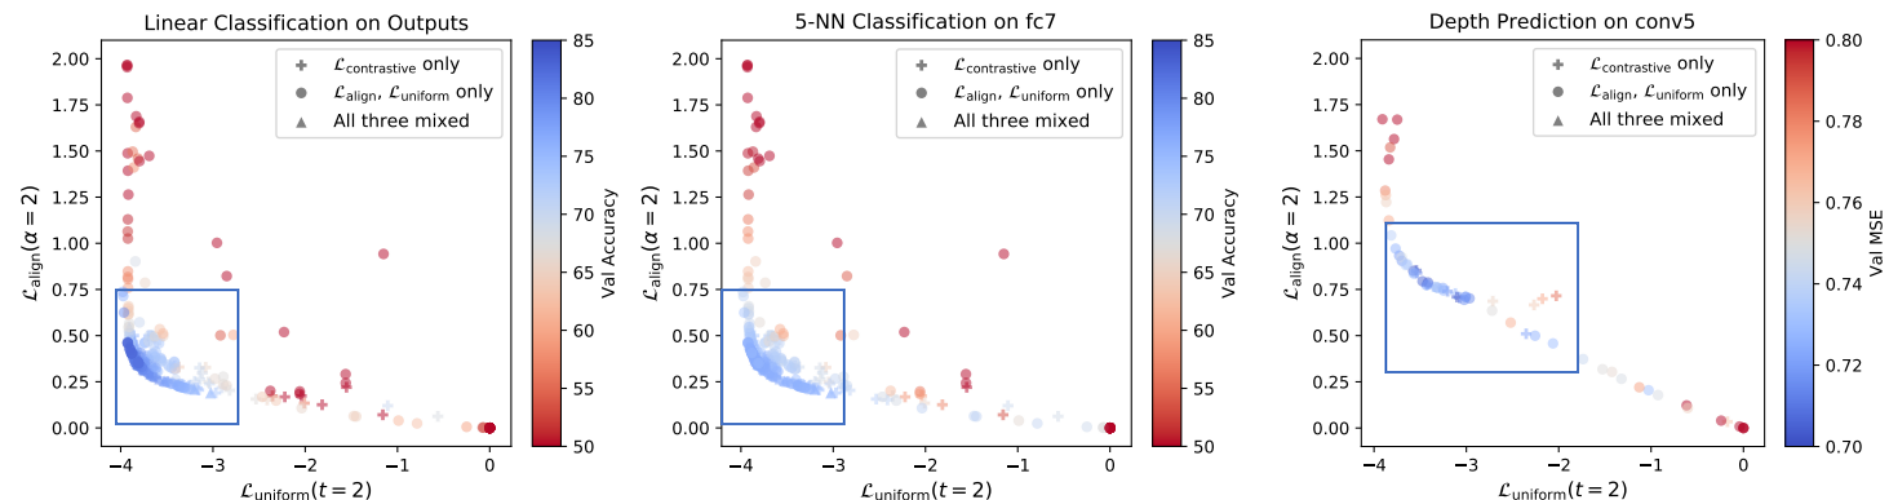
$$\mathcal{L}_{\text{align}}(f; \alpha) \triangleq \mathbb{E}_{(x, y) \sim p_{\text{pos}}} [\|f(x) - f(y)\|_2^\alpha], \quad \alpha > 0.$$

$$\begin{aligned} \mathcal{L}_{\text{uniform}}(f; t) &\triangleq \log \mathbb{E}_{\substack{\text{i.i.d.} \\ x, y \sim p_{\text{data}}}} [G_t(u, v)] \\ &= \log \mathbb{E}_{\substack{\text{i.i.d.} \\ x, y \sim p_{\text{data}}}} \left[ e^{-t \|f(x) - f(y)\|_2^2} \right], \quad t > 0. \end{aligned}$$

# • Experiments

## ❖ Relationship between Contrastive Loss, Alignment, and Uniformity

- Contrastive loss만을 사용할 때, 앞에서 정의한 Alignment와 uniformity 함수를 loss로 사용할 때, 세 함수 모두를 목적함수로 사용할 때의 alignment와 uniformity 값을 비교
- Alignment(y축)와 uniformity(x축)의 값이 모두 작을 (왼쪽 모서리) 경우 가장 성능이 좋으며(파란색), contrastive loss만을 쓸 때에도 두 값이 작을 때 성능이 좋음



# • Experiments

## ❖ Relationship between Contrastive Loss, Alignment, and Uniformity

- 또한, contrastive loss를 사용하지 않고 본 논문에서 정의한 alignment와 uniformity를 직접 목적함수로 사용하여 최적화하는 것이 약간의 성능향상을 보임

	Loss Formula	Validation Set Accuracy ↑			
		Output + Linear	Output + 5-NN	fc7 + Linear	fc7 + 5-NN
Best $\mathcal{L}_{\text{contrastive}}$ only	$\mathcal{L}_{\text{contrastive}}(\tau=0.19)$	80.46%	78.75%	83.89%	76.33%
Best $\mathcal{L}_{\text{align}}$ and $\mathcal{L}_{\text{uniform}}$ only	$0.98 \cdot \mathcal{L}_{\text{align}}(\alpha=2) + 0.96 \cdot \mathcal{L}_{\text{uniform}}(t=2)$	<b>81.15%</b>	78.89%	<b>84.43%</b>	<b>76.78%</b>
Best among all encoders	$\mathcal{L}_{\text{contrastive}}(\tau=0.5) + \mathcal{L}_{\text{uniform}}(t=2)$	81.06%	<b>79.05%</b>	84.14%	76.48%

Table 1: STL-10 encoder evaluations. Numbers show linear and 5-nearest neighbor (5-NN) classification accuracies on the validation set. The best result is picked by encoder outputs linear classifier accuracy from a 5-fold training set cross validation, among all 150 encoders trained from scratch with 128-dimensional output and 768 batch size.

	Loss Formula	Validation Set MSE ↓	
		conv5	conv4
Best $\mathcal{L}_{\text{contrastive}}$ only	$0.5 \cdot \mathcal{L}_{\text{contrastive}}(\tau=0.1)$	0.7024	<b>0.7575</b>
Best $\mathcal{L}_{\text{align}}$ and $\mathcal{L}_{\text{uniform}}$ only	$0.75 \cdot \mathcal{L}_{\text{align}}(\alpha=2) + 0.5 \cdot \mathcal{L}_{\text{uniform}}(t=2)$	<b>0.7014</b>	0.7592
Best among all encoders	$0.75 \cdot \mathcal{L}_{\text{align}}(\alpha=2) + 0.5 \cdot \mathcal{L}_{\text{uniform}}(t=2)$	<b>0.7014</b>	0.7592

Table 2: NYU-DEPTH-V2 encoder evaluations. Numbers show depth prediction mean squared error (MSE) on the validation set. The best result is picked based on conv5 layer MSE from a 5-fold training set cross validation, among all 64 encoders trained from scratch with 128-dimensional output and 128 batch size.

# • Experiments

## ❖ Relationship between Alignment and Uniformity

- Alignment와 Uniformity의 각 목적함수 별 weight를 변경해 가면서 실험
- 맨 왼쪽은 alignment 목적함수만 사용한 것이며 맨 오른쪽은 uniformity 목적함수만 사용
- 양 극단으로 갈수록(하나의 목적함수만 사용) 성능이 급격히 떨어지며 두 목적함수를 적절하게 같이 사용하는 것이 좋은 성능을 보임
- 이를 통해 alignment와 uniformity가 동시에 최적화 되어야 좋은 성능을 보임을 확인




Figure 7: Effect of optimizing different weighted combinations of  $\mathcal{L}_{\text{align}}(\alpha=2)$  and  $\mathcal{L}_{\text{uniform}}(t=2)$  for STL-10. For each encoder, we show the  $\mathcal{L}_{\text{align}}$  and  $\mathcal{L}_{\text{uniform}}$  metrics, and validation accuracy of a linear classifier trained on encoder outputs.  $\mathcal{L}_{\text{uniform}}$  is exponentiated for plotting purposes.

# • Summary & Conclusions

---

## ❖ Summary

- 본 논문에서는 contrastive representation learning이 alignment와 uniformity를 최적화하는 방향으로 학습된다고 주장
- 이 증명을 위해 alignment와 uniformity를 l-norm과 가우시안 필터로 정량화한 뒤 다양한 실험을 통해서 자신의 주장을 증명
- 이를 통해 기존에 Mutual Information을 최대화한다는 해석보다 더욱 직관적으로 해석하고 이해하는 것에 도움을 줌

## ❖ Conclusions

- Contrastive learning과 alignment, uniformity 간의 관계를 보여주는 수식 전개 과정은 너무 어려워서 넘어 갔음
- 하지만 Representation learning이 어떻게 학습되는지 시각적으로 보여줘서 논문 제목 그대로 이해하기 좋았음
- 다만 두 목적함수를 사용한다면 weight search가 힘들 것 같아서 그냥 contrastive loss를 사용하는 것이 더 좋아 보였음

# • Reference

---

## ❖ **Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere**

1. Wang, Tongzhou, and Phillip Isola. "Understanding contrastive representation learning through alignment and uniformity on the hypersphere." *International Conference on Machine Learning*. PMLR, 2020.
2. <https://velog.io/@kimkj38/%EB%85%BC%EB%AC%B8-%EB%A6%AC%EB%B7%B0-Understanding-Contrastive-Representation-Learning-through-Alignment-and-Uniformity-on-the-Hypersphere>

# • Appendix A

## ❖ proof of the positive semi-definite of Laplacian

임의의  $x \in \mathbb{R}^N$  에 대해,

$$\begin{aligned} x^T Lx &= x^T Dx - x^T Wx = \sum_i D_{ii}x_i^2 - \sum_{i,j} x_i W_{ij}x_j \\ &= \frac{1}{2} \left( 2 \sum_i D_{ii}x_i^2 - 2 \sum_{i,j} W_{ij}x_i x_j \right) \\ &\stackrel{(a)}{=} \frac{1}{2} \left( 2 \sum_i \left\{ \sum_j W_{ij} \right\} x_i^2 - 2 \sum_{i,j} W_{ij}x_i x_j \right) \\ &\stackrel{(b)}{=} \frac{1}{2} \left( \sum_{i,j} W_{ij}x_i^2 + \sum_{i,j} W_{ij}x_j^2 - 2 \sum_{i,j} W_{ij}x_i x_j \right) \\ &= \frac{1}{2} \sum_{i,j} W_{ij}(x_i - x_j)^2 \geq 0 \end{aligned} \tag{2}$$



*Thank You*