

---

# FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

---

School of Industrial and Management Engineering, Korea University

Lee Kyung Yoo

# Contents

---

- ❖ Research Purpose
- ❖ FixMatch
- ❖ Experiments
- ❖ Conclusion

# Research Purpose

---

- ❖ **FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence (NeurIPS, 2020)**
  - Google research에서 연구된 논문이며, 2022년 08월 26일 기준으로 1,075회 인용됨

---

## FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

---

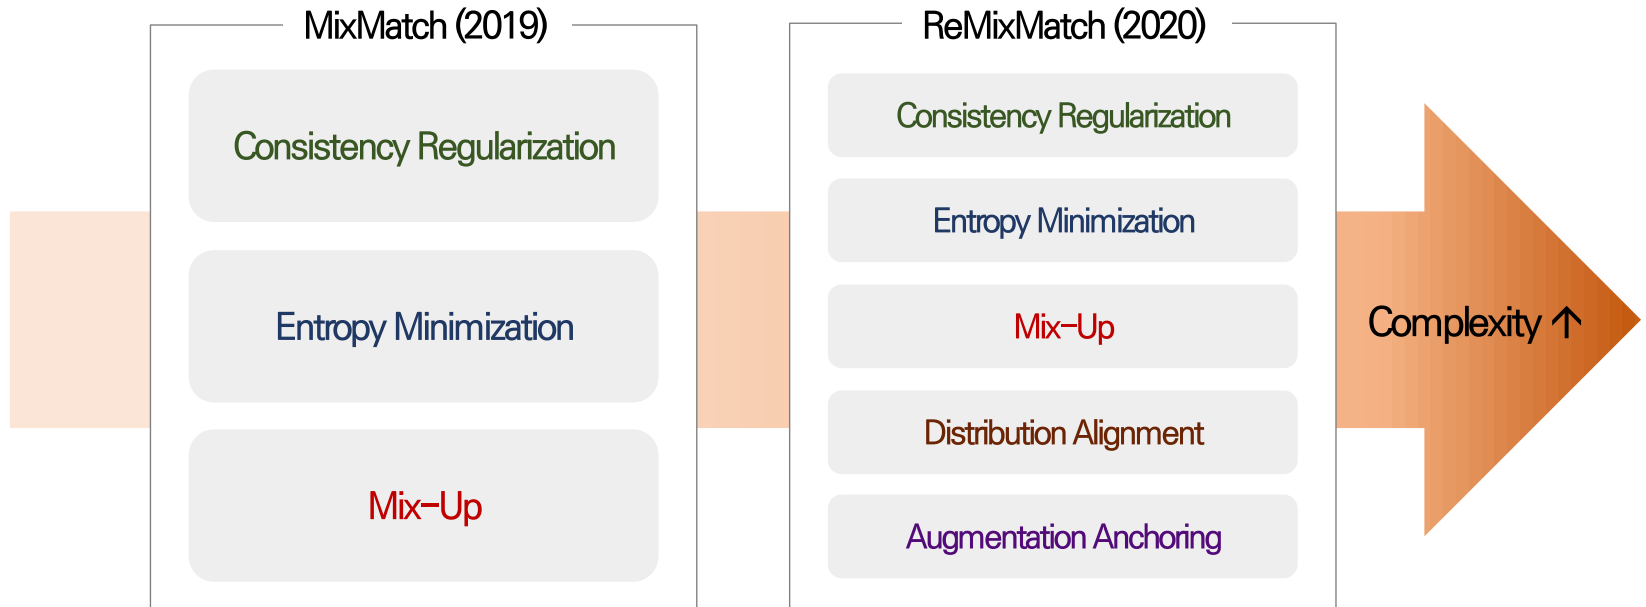
Kihyuk Sohn\* David Berthelot\* Chun-Liang Li Zizhao Zhang Nicholas Carlini  
Ekin D. Cubuk Alex Kurakin Han Zhang Colin Raffel  
Google Research  
{kihyuks, dberth, chunliang, zizhaoz, ncarlini,  
cubuk, kurakin, zhanghan, craffel}@google.com

### Abstract

Semi-supervised learning (SSL) provides an effective means of leveraging unlabeled data to improve a model's performance. This domain has seen fast progress recently, at the cost of requiring more complex methods. In this paper we propose FixMatch, an algorithm that is a significant simplification of existing SSL methods. FixMatch first generates pseudo-labels using the model's predictions on weakly-augmented unlabeled images. For a given image, the pseudo-label is only retained if the model produces a high-confidence prediction. The model is then trained to predict the pseudo-label when fed a strongly-augmented version of the same image. Despite its simplicity, we show that FixMatch achieves state-of-the-art performance across a variety of standard semi-supervised learning benchmarks, including 94.93% accuracy on CIFAR-10 with 250 labels and 88.61% accuracy with 40 – just 4 labels per class. We carry out an extensive ablation study to tease apart the experimental factors that are most important to FixMatch's success. The code is available at <https://github.com/google-research/fixmatch>.

# Research Purpose

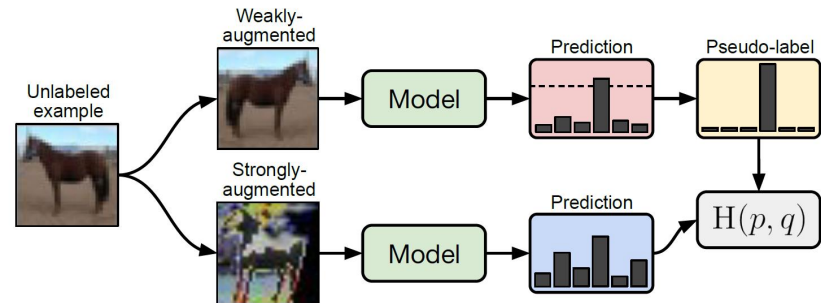

- ❖ FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence (NeurIPS, 2020)
  - 기존 방법론들은 성능 고도화를 위해 주요 기법들을 추가 및 혼합하는 방향으로 발전
  - 이는 지나치게 정교한 loss term과 조정하기 어려운 수많은 hyperparameter를 사용하는 형태
    - 알고리즘이 점점 더 복잡해지는 한계를 지님



# Research Purpose

## ❖ FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence (NeurIPS, 2020)

- FixMatch는 이러한 복잡한 메커니즘들을 결합하는 트렌드를 역행하고자 함
- Consistency regularization과 pseudo labeling 두 기법 만을 결합한 간단한 구조로 구성
  - 기존 방법론 대비 가장 우수한 성능을 보임

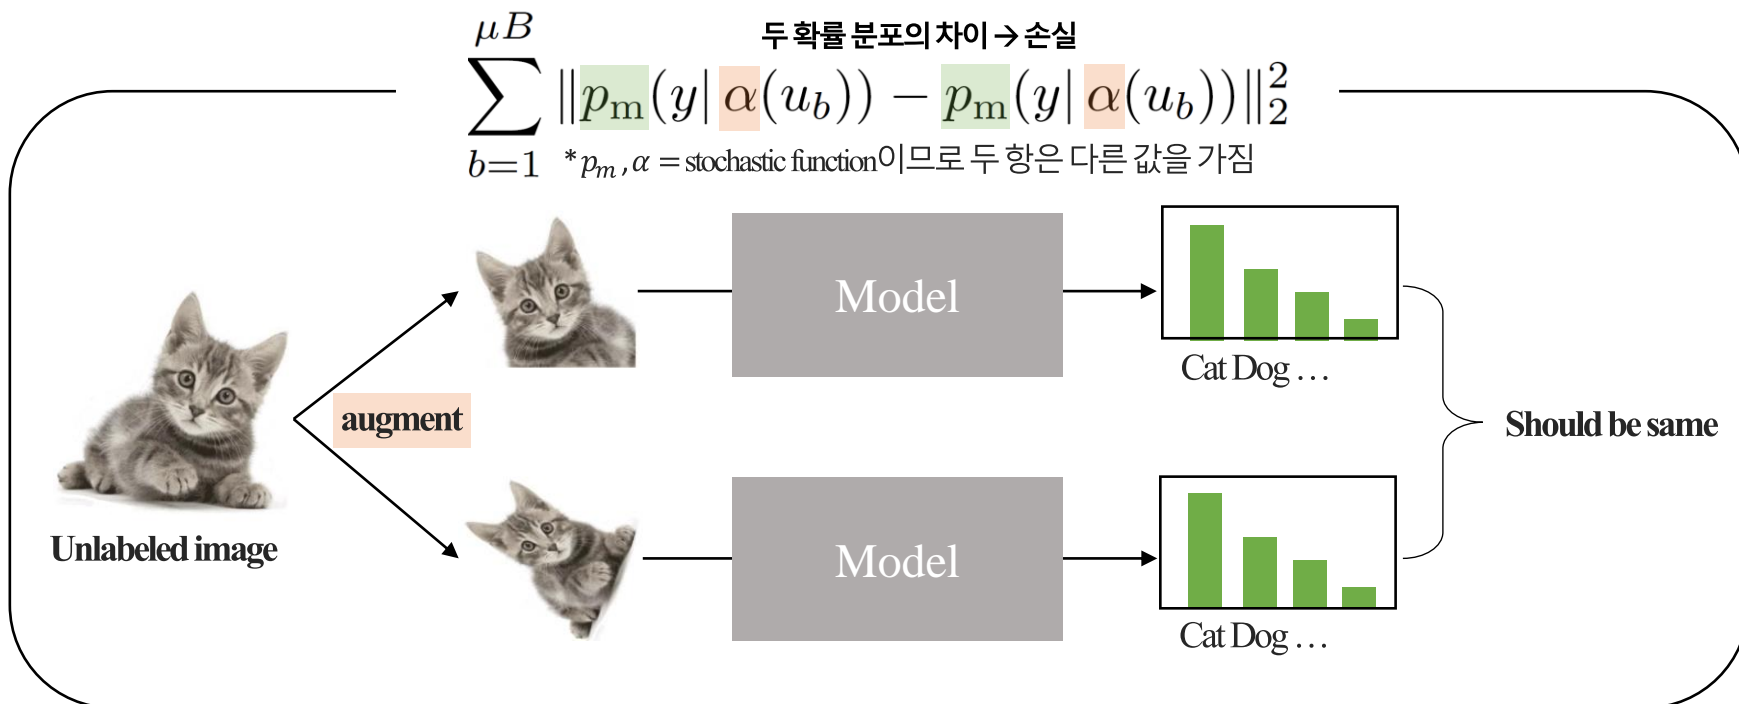


“ Simple is the best! ”

# FixMatch

## ❖ Background - (1) Consistency regularization

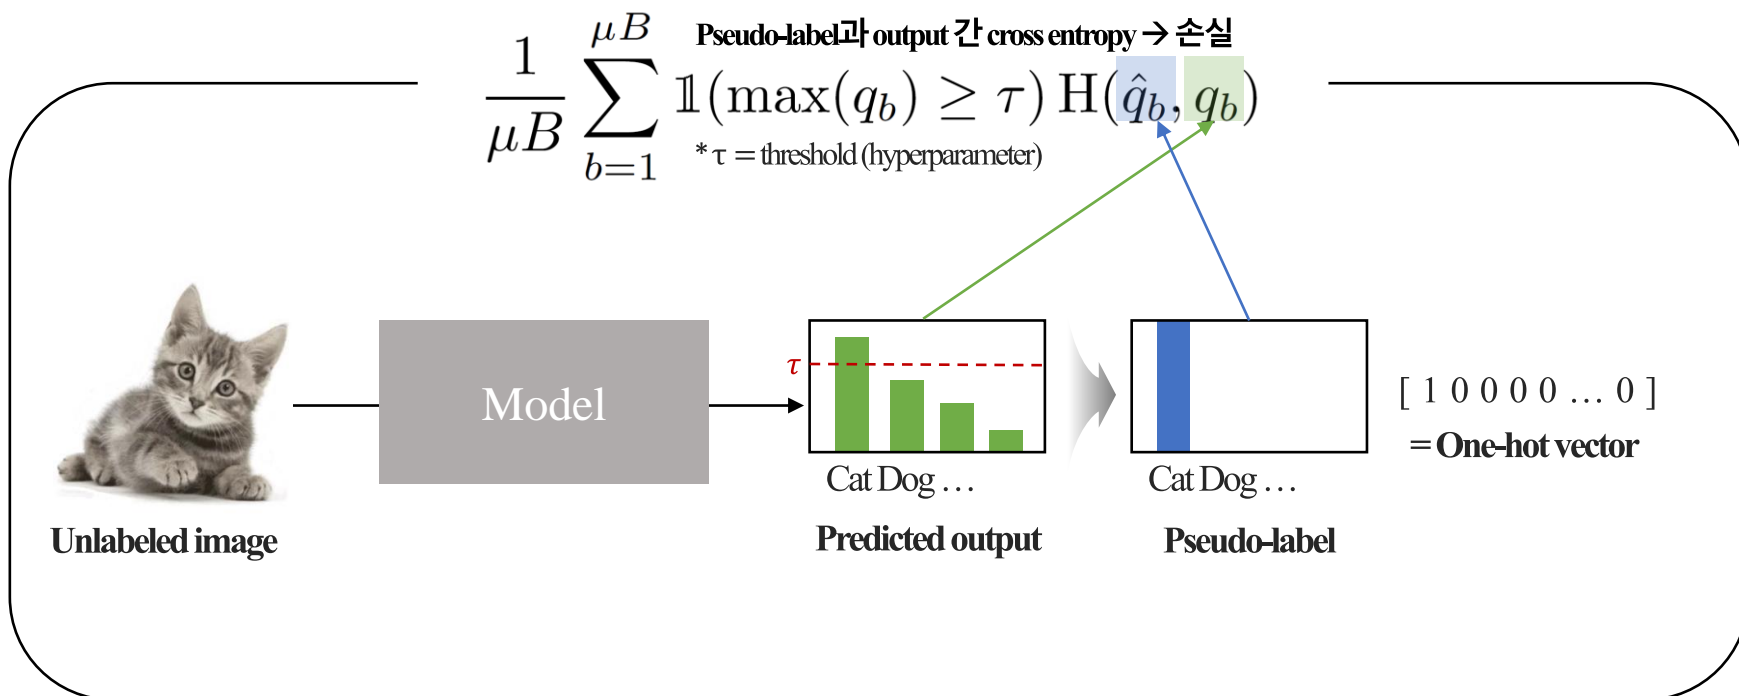
- 이미지에 가해진 약간의 변형에도 레이블 값은 변하지 않는다는 점 이용
  - 고양이 이미지에 아래와 같이 변형을 가해도 “고양이”라는 레이블은 변하지 않음
- 하나의 unlabeled data에 여러 변형을 통해 augmented data 생성
- Labeled data를 통해 학습된 모델에 통과시켜, 각각의 예측 확률 분포를 동일하게 만들도록 학습



# FixMatch

## ❖ Background - (2) Pseudo labeling

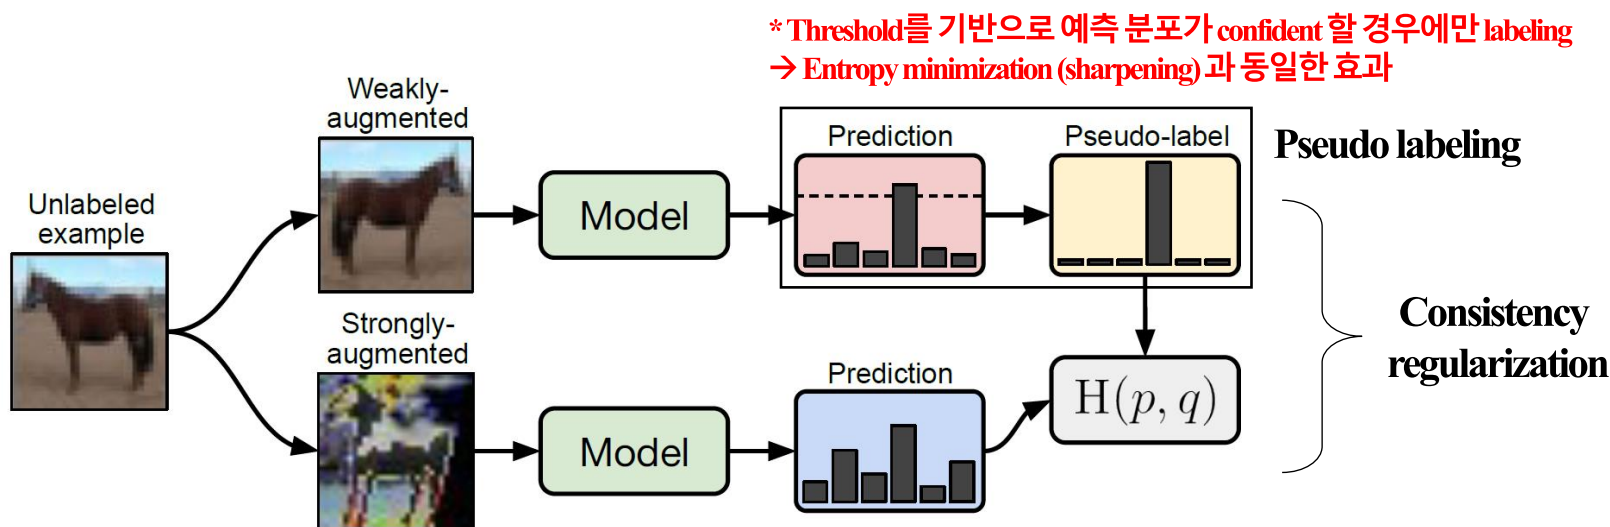
- Labeled data를 통해 학습된 모델에 통과시켜, unlabeled data의 레이블 값을 예측
- 예측값들 중 가장 높은 확률에 해당하는 값으로 새로운 레이블 부여 = pseudo-labeled data
  - 확률이 사전에 정의한 threshold를 넘을 경우에만 pseudo-labeled data로 사용
- Pseudo-labeled data와 기존 labeled data를 가지고 모델을 최종 학습시킴



# FixMatch

## ❖ Overall framework

- Step 1. labeled data에 대해 weak augmentation 적용 후, 모델 학습
- Step 2. unlabeled data에 대해 weak augmentation 적용 후, 모델에 통과시켜 얻어낸 예측값을 기반으로 pseudo-label 생성
- Step 3. 동일한 unlabeled data에 대해 strong augmentation 적용 후, 모델에 통과시켜 얻어낸 예측값과 앞서 생성한 pseudo-label이 비슷해지도록 학습





# FixMatch

## ❖ Loss function

- Supervised loss (labeled data)

$$\ell_s = \frac{1}{B} \sum_{b=1}^B H(p_b, p_m(y \mid \alpha(x_b)))$$

✓  $p_b$ : label (one-hot vector)

✓  $p_m$ : weakly augmented data의 prediction probability

- Unsupervised loss (unlabeled data)

$$\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbb{1}(\max(q_b) \geq \tau) H(\hat{q}_b, p_m(y \mid \mathcal{A}(u_b)))$$

✓  $q_b$ : weakly augmented data의 prediction probability /  $\hat{q}_b$ : pseudo-label (one-hot vector)

✓  $p_m$ : strongly augmented data의 prediction probability

- Total loss

$$\ell_s + \lambda_u \ell_u$$

Unsupervised loss의 영향력을 결정하는 값으로, FixMatch에서는 threshold 덕분에 따로 조절 X  
⇒ 학습을 진행할수록 FixMatch 내 threshold를 넘는 unlabeled data가 초반보다 많아질 것

## ❖ Augmentation in FixMatch

- 본 논문에서 설정한 augmentation 기법은 크게 weak / strong augmentation으로 나누어 적용
- Weak augmentation : Standard flip-and-shift
  - Horizontal flip with probability 50%
  - Randomly translate up to 12.5% vertically & horizontally
- Strong augmentation : AutoAugment
  - RandAugment, CTAugment
  - RandAugment, CTAugment 적용 후 반드시 Cutout을 다시 적용
  - MixUp 혹은 Adversarial perturbations와 같은 기법으로 대체 가능

# Experiments

## ❖ Results (CIFAR-10, CIFAR-100, SVHN)

- Labeled data의 서로 다른 5개의 folds를 학습할 때 mean과 variance를 측정
- Labeled data가 40개 밖에 없는 극한의 상황에서도 FixMatch가 타 모델 대비 우수한 성능을 보임
- 그러나, CIFAR-100에서는 FixMatch가 ReMixMatch보다 성능이 더 좋지 않은 경우가 발생함
  - 모든 클래스에 대해 동일한 확률을 방출하도록 하는 Distribution Alignment를 적용하면 성능이 ReMixMatch보다 더 좋아짐을 확인

	CIFAR-10			CIFAR-100			SVHN		
Method	40 labels	250 labels	4000 labels	400 labels	2500 labels	10000 labels	40 labels	250 labels	1000 labels
II-Model	-	54.26 $\pm$ 3.97	14.01 $\pm$ 0.38	-	57.25 $\pm$ 0.48	37.88 $\pm$ 0.11	-	18.96 $\pm$ 1.92	7.54 $\pm$ 0.36
Pseudo-Labeling	-	49.78 $\pm$ 0.43	16.09 $\pm$ 0.28	-	57.38 $\pm$ 0.46	36.21 $\pm$ 0.19	-	20.21 $\pm$ 1.09	9.94 $\pm$ 0.61
Mean Teacher	-	32.32 $\pm$ 2.30	9.19 $\pm$ 0.19	-	53.91 $\pm$ 0.57	35.83 $\pm$ 0.24	-	3.57 $\pm$ 0.11	3.42 $\pm$ 0.07
MixMatch	47.54 $\pm$ 11.50	11.05 $\pm$ 0.86	6.42 $\pm$ 0.10	67.61 $\pm$ 1.32	39.94 $\pm$ 0.37	28.31 $\pm$ 0.33	42.55 $\pm$ 14.53	3.98 $\pm$ 0.23	3.50 $\pm$ 0.28
UDA	29.05 $\pm$ 5.93	8.82 $\pm$ 1.08	4.88 $\pm$ 0.18	59.28 $\pm$ 0.88	33.13 $\pm$ 0.22	24.50 $\pm$ 0.25	52.63 $\pm$ 20.51	5.69 $\pm$ 2.76	<b>2.46</b> $\pm$ 0.24
ReMixMatch	<b>19.10</b> $\pm$ 9.64	<b>5.44</b> $\pm$ 0.05	4.72 $\pm$ 0.13	<b>44.28</b> $\pm$ 2.06	<b>27.43</b> $\pm$ 0.31	<b>23.03</b> $\pm$ 0.56	<b>3.34</b> $\pm$ 0.20	<b>2.92</b> $\pm$ 0.48	2.65 $\pm$ 0.08
FixMatch (RA)	<b>13.81</b> $\pm$ 3.37	<b>5.07</b> $\pm$ 0.65	<b>4.26</b> $\pm$ 0.05	48.85 $\pm$ 1.75	28.29 $\pm$ 0.11	<b>22.60</b> $\pm$ 0.12	<b>3.96</b> $\pm$ 2.17	<b>2.48</b> $\pm$ 0.38	<b>2.28</b> $\pm$ 0.11
FixMatch (CTA)	<b>11.39</b> $\pm$ 3.35	<b>5.07</b> $\pm$ 0.33	<b>4.31</b> $\pm$ 0.15	49.95 $\pm$ 3.01	28.64 $\pm$ 0.24	23.18 $\pm$ 0.11	7.65 $\pm$ 7.65	<b>2.64</b> $\pm$ 0.64	<b>2.36</b> $\pm$ 0.19

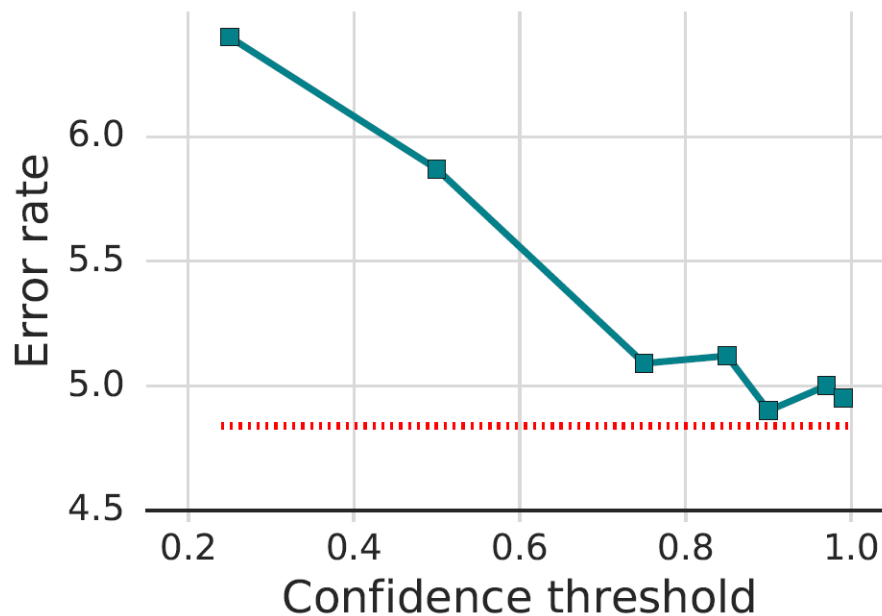
	CIFAR-10			CIFAR-100			SVHN		
Method	40 labels	250 labels	4000 labels	400 labels	2500 labels	10000 labels	40 labels	250 labels	1000 labels
Supervised (RA)	64.01 $\pm$ 0.76	39.12 $\pm$ 0.77	12.74 $\pm$ 0.29	79.47 $\pm$ 0.18	52.88 $\pm$ 0.51	32.55 $\pm$ 0.21	52.68 $\pm$ 2.29	22.48 $\pm$ 0.55	10.89 $\pm$ 0.12
Supervised (CTA)	64.53 $\pm$ 0.83	41.92 $\pm$ 1.17	13.64 $\pm$ 0.12	79.79 $\pm$ 0.59	54.23 $\pm$ 0.48	35.30 $\pm$ 0.19	43.05 $\pm$ 2.34	15.06 $\pm$ 1.02	7.69 $\pm$ 0.27

\* Wide ResNet-28-2 for CIFAR-10, SVHN / Wide ResNet-28-8 for CIFAR-100

# Experiments

## ❖ Ablation study (CIFAR-10)

- Pseudo labeling에서 사용하는 threshold를 여러 값으로 조정하며 실험 → thresholding 영향 분석
  - Threshold 값이 커질수록 error rate가 작아지는 경향
  - 이를 통해, unlabeled data의 양보다는 질이 모델 성능에 더 중요함을 확인 가능




\* ..... : FixMatch의 lower bound 성능

# Experiments

## ❖ Ablation study (CIFAR-10)

- Sharpening에서 사용하는 temperature를 여러 값으로 조정하며 실험 → sharpening 영향 분석
  - Temperature와 threshold 값을 바꾸면서 실험한 결과 모두 FixMatch(Temperature=0)의 성능 미만
  - 단순 thresholding을 이용한 pseudo labeling이 sharpening보다 더 좋은 효과를 보임



\* ..... : FixMatch의 lower bound 성능

# Experiments

## ❖ Barely supervised learning (CIFAR-10)

- FixMatch의 한계를 검증하기 위해, 클래스당 하나의 random example만을 가지도록 설정한 후 실험
- 총 4개의 데이터셋 생성 후, 각각의 데이터셋에 대해 4번씩 실험
- 예측 결과, 48.58%~85.32%의 성능에 해당하는 큰 변동성을 보임
  - 이는 random example의 quality에 기인했다고 저자는 서술
  - 각 클래스를 제일 잘 나타내는 대표 이미지들을 뽑아 실험한 결과, 중앙값이 78%인 성능 달성



Figure 2: FixMatch reaches 78% CIFAR-10 accuracy using only above 10 labeled images.

# Conclusion

---

## ❖ Conclusion

- Consistency regularization과 pseudo labeling을 결합하여 semi-supervised learning 방법론을 단순화
- 검증된 augmentation 기법들 또한 두 SSL 기법 못지 않게 우수한 성능에 기여
- 방대한 ablation study를 기반으로, 간단한 모델이 어떻게 SOTA를 달성할 수 있었는지에 대해 상세히 서술한 점이 인상적이었음

## ❖ Reference

- Sohn, K., Berthelot, D., Carlini, N., Zhang, Z., Zhang, H., Raffel, C. A., ... & Li, C. L. (2020). Fixmatch: Simplifying semi-supervised learning with consistency and confidence. Advances in neural information processing systems, 33, 596-608.
- <http://dsba.korea.ac.kr/seminar/?mod=document&uid=248>
- <https://2-chae.github.io/category/2.papers/29>

*Thank You*